



UNIVERSIDAD
CATÓLICA
BOLIVIANA
COCHABAMBA

Departamento de Ingeniería y Ciencias Exactas

Examen Primera Sesión

“Sistema de Análisis y Predicción de Rendimiento de Futbolistas”

Modelado y simulación de datos

**Mateo Gael Figueroa Chavez
Nataly Ramirez Machicado
Josue Junior Camacho Canaviri
Ostin Lisandro Colque Rivas**

*Cochabamba - Bolivia
12-2025*

1. Introducción

Problema

Evaluar y predecir habilidades de jugadores de fútbol profesional usando datos históricos y atributos técnicos, físicos y mentales.

Objetivos

- Integrar múltiples técnicas de modelado en un sistema coherente
- Aplicar integración numérica a problemas de evolución temporal
- Implementar filtros de Kalman para estimación de estado
- Diseñar y entrenar modelos de machine learning
- Desarrollar habilidades de trabajo en equipo y gestión de proyectos

Motivación

Comprender qué factores influyen más en el rendimiento de un jugador y desarrollar un sistema predictivo automatizado.

2. Dataset y Preprocesamiento

DIA 1

Desafíos

El dataset de entrenamiento inicial presentó desafíos que impedían la aplicación directa de modelos lineales:

1. **Registros Históricos Múltiples:** Necesidad de seleccionar o agregar múltiples registros por jugador para obtener una instancia única.
2. **Valores Nulos y Dimensionalidad:** Presencia de valores nulos en atributos clave y una alta dimensionalidad inicial, lo que aumentaba el riesgo de sesgo por imputación simple y **multicolinealidad** entre predictores.
3. **Bajo Rendimiento Inicial:** El objetivo de rendimiento establecido era un $RMSE < 2.0$ y $R^2 > 0.85$.

Decisiones técnicas

Primer Entrenamiento (Modelo Base)

- **Selección de Datos:** Se seleccionó el registro **más reciente** por jugador.
- **Imputación:** Se construyó un pipeline base:
 - Variables numéricas: Imputación con la **mediana**.
 - Variables categóricas: Imputación con la **moda**.
- **Codificación y Escalamiento:** Se aplicó **One-Hot Encoding** para categorías y **Normalización Min-Max** para numéricas.

- **Modelo:** Se utilizó una **Regresión Lineal** estándar con 15 variables predictoras.
- **Evaluación:** Se usó **Validación Cruzada K-Fold (k=5)**.

Resultados Iniciales: RMSE = 2.98 y $R^2 = 0.75$. El análisis del Factor de Inflación de Varianza (VIF) confirmó la **alta multicolinealidad**.

Segundo Entrenamiento (Optimización y Regularización)

- Limpieza y Preprocesamiento Avanzado:
 - Eliminación de registros duplicados y manejo de valores atípicos mediante el método del Rango Intercuartílico (IQR).
 - Uso de StandardScaler para estandarizar las características numéricas.
- Ingeniería de Características: Generación de interacciones polinomiales de segundo grado sobre las características estandarizadas.
- Ajuste de Hiperparámetros: Uso de GridSearchCV para optimizar el parámetro de regularización alpha.

Resultados Finales: El RMSE promedio se redujo a 1.82 y el R^2 se elevó a 0.91, cumpliendo los objetivos. Esto demostró la importancia de las interacciones polinomiales y la regularización para mejorar la predicción.

Variables derivadas

Para reducir la dimensionalidad y capturar conceptos de alto nivel, se crearon tres variables derivadas como promedios simples de atributos relacionados:

- **score_fisico:** Promedio de **acceleration**, **sprint_speed**, **stamina** y **strength**.
- **score_tecnico:** Promedio de **ball_control**, **dribbling** y **short_passing**.
- **score_mental:** Promedio de **positioning**, **vision** y **reactions**.

DÍA 2

Desafíos

1. Complejidad de implementación desde cero:

La necesidad de implementar redes neuronales completamente desde cero en NumPy, incluyendo forward propagation, backpropagation, y optimización, sin depender de frameworks como TensorFlow o PyTorch.

2. Manejo de datos para dos tareas diferentes:

Preparar los mismos datos para dos objetivos distintos: regresión (potencial) y clasificación (perfil), requiriendo diferentes preprocesamientos, normalizaciones y divisiones de características.

3. Selección óptima de arquitecturas:

Determinar las arquitecturas apropiadas para cada red neuronal (número de capas, neuronas por capa, funciones de activación) sin sobreajuste o subajuste.

4. Validación cruzada estricta:

Implementar validación cruzada tanto para regresión (K-Fold) como para clasificación (Stratified K-Fold) manteniendo la integridad de los conjuntos de datos.

5. Análisis de importancia sin SHAP:

Necesidad de implementar métodos alternativos para calcular la importancia de características ante la imposibilidad de usar la librería SHAP.

6. Manejo de clases desbalanceadas:

En la clasificación de perfiles, asegurar que todas las clases (tipos de jugador) estén representadas adecuadamente y que el modelo no se sesgue hacia clases mayoritarias.

Decisiones técnicas

1. Implementación modular de redes neuronales:

- Se crearon dos clases separadas: `NeuralNetworkRegressor` para regresión y `NeuralNetworkClassifier` para clasificación.
- Ambas implementan inicialización Xavier/Glorot para estabilizar el entrenamiento.
- Uso de regularización L2 para prevenir sobreajuste.

2. Arquitecturas específicas por tarea:

- Red 1 (Regresión):

Arquitectura [n_features, 256, 128, 64, 1] con activación ReLU en capas ocultas y función lineal en salida.

- Red 2 (Clasificación):

Arquitectura [n_features, 256, 128, n_classes] con activación ReLU y softmax en salida.

3. Preparación de datos diferenciada:

- Para Red 1:

Se seleccionaron 20 características relacionadas con atributos de juego y métricas derivadas.

- Para Red 2:

Se usaron 15 características balanceadas y se creó la variable `player\_profile` con 7 categorías basadas en atributos dominantes.

4. Métodos de evaluación robustos:

- División 70-15-15 para entrenamiento, validación y test.
- Implementación de K-Fold para regresión y Stratified K-Fold para clasificación.
- Métricas completas: MAE, RMSE, R^2 para regresión; Accuracy, Precision, Recall, F1, AUC-ROC para clasificación.

5. Análisis de importancia por permutación:

- Se implementó un método manual que calcula la importancia permutando cada característica y midiendo el cambio en las métricas.
- Para regresión: cambio en MAE.
- Para clasificación: cambio en Accuracy.

6. Sistema de visualización integral:

- 9 gráficos principales que muestran curvas de aprendizaje, predicciones vs reales, matrices de confusión, y comparativas de métricas.
- Visualizaciones específicas para análisis de errores y residuos.

Variables derivadas

1. Variables para análisis de potencial (Red 1):

- `potential\_diff`: Diferencia entre potencial y overall_rating.
- `attack\_score`: Promedio de finishing, shot_power, long_shots.
- `defense\_score`: Promedio de marking, standing_tackle, sliding_tackle.
- `speed\_score`: Promedio de acceleration, sprint_speed, agility.

2. Variables para clasificación de perfil (Red 2):

- `player\_profile`: Variable categórica con 7 clases definidas algorítmicamente basadas en atributos dominantes:
 - Goalkeeper (portero)
 - Central Defender (defensa central)
 - Full Back (lateral)
 - Defensive Midfielder (medio defensivo)
 - Central Midfielder (medio centro)
 - Attacking Midfielder (medio ofensivo)

- Forward (delantero)

3. Métricas de evaluación derivadas:

- `avg\_metrics\_red1`: Promedios de validación cruzada para la red de regresión.
- `avg\_metrics\_red2`: Promedios de validación cruzada para la red de clasificación.
- `importancias\_red1`: Ranking de importancia de características para predicción de potencial.
- `importancias\_red2`: Ranking de importancia de características para clasificación de perfil.

4. Archivos y modelos persistentes:

- `modelos\_redes.pkl`: Archivo serializado que contiene ambos modelos entrenados, características usadas, label encoders y métricas.

5. Insights de rendimiento:

- Mejoras porcentuales vs modelos baseline.
- Análisis de errores sistemáticos por rango de potencial y por clase de perfil.
- Distribución de residuos y patrones de error identificados.

DÍA 3

Desafíos

1. Integración de sistemas complejos:

Combinar las redes neuronales del Día 2 con un sistema dinámico basado en ecuaciones diferenciales, manteniendo consistencia entre los modelos predictivos y las simulaciones.

2. Modelado de trayectorias realistas:

Crear ecuaciones diferenciales que representen de manera realista la evolución de atributos físicos, técnicos y mentales de futbolistas a lo largo del tiempo, considerando factores como edad, lesiones y fatiga.

3. Selección de parámetros adecuados:

Determinar valores realistas para los parámetros del sistema dinámico (tasas de crecimiento, decaimiento, interacciones entre variables) que reflejen el comportamiento real de los jugadores.

4. Comparación de métodos numéricos:

Implementar y evaluar diferentes métodos de integración numérica (Euler vs RK4) para resolver las ecuaciones diferenciales, asegurando estabilidad y precisión en las simulaciones a largo plazo.

5. Validación de escenarios múltiples:

Diseñar y evaluar 5 escenarios diferentes de desarrollo de jugadores, cada uno con características únicas que representen perfiles reales del mundo del fútbol.

6. Automatización del análisis:

Crear un sistema que analice automáticamente múltiples jugadores sin requerir intervención manual, generando reportes completos y visualizaciones.

Decisiones técnicas

1. Sistema de ecuaciones diferenciales acopladas:

Se implementaron 5 ecuaciones diferenciales que modelan la evolución de:

- **F:** Aptitud física (influenciada por edad óptima y entrenamiento)
- **T:** Habilidad técnica (con sinergia positiva desde lo físico)
- **M:** Capacidad mental (con aporte de físico y técnico)
- **R:** Rating global FIFA (combinación ponderada de las anteriores)
- **A:** Edad (variable temporal)

2. Parámetros por escenario:

- 5 perfiles diferenciados: joven_promesa, late_bloomer, balanceado, early_bloomer, lento_seguro
- Cada perfil con tasas de crecimiento (α), decaimiento (β), sinergias (γ, δ), y edades óptimas específicas
- Pesos diferenciados (w_F, w_T, w_M) según el tipo de jugador

3. Métodos de integración numérica:

- **Método de Euler:** Implementación simple para comparación
- **Runge-Kutta de orden 4 (RK4):** Método principal para mayor precisión
- Paso temporal diario ($h = 1$ día) para simular años completos

4. Factores de perturbación realistas:

- **Lesiones:** Implementadas como reducción temporal de efectividad de entrenamiento (70% físico, 50% técnico, 30% mental)
- **Fatiga:** Efecto acumulativo proporcional al tiempo de competición
- **Edad óptima:** Distribución gaussiana centrada en edades específicas por perfil

5. Sistema de análisis automatizado:

- Selección aleatoria pero representativa de 5 jugadores para casos de estudio
- Análisis comparativo completo entre escenarios y métodos
- Generación automática de reportes en CSV y TXT
- Creación de dashboards visuales con matplotlib

6. Optimización de entrenamiento:

- Sistema para probar múltiples combinaciones de intensidad de entrenamiento (EF, ET, EM)
- Búsqueda del régimen óptimo que maximice el rating final
- Análisis de sensibilidad a cambios en parámetros clave

Variables derivadas

1. Variables de estado del sistema:

- $F(t)$: Nivel físico normalizado (0-1)
- $T(t)$: Nivel técnico normalizado (0-1)
- $M(t)$: Nivel mental normalizado (0-1)
- $R(t)$: Rating FIFA (40-95)
- $A(t)$: Edad en años

2. Parámetros específicos por escenario:

- $\alpha_F, \alpha_T, \alpha_M$: Tasas de crecimiento de atributos
- $\beta_F, \beta_T, \beta_M$: Tasas de decaimiento por edad
- γ_{FT} : Sinergia físico→técnico
- δ : Contribución combinada físico+técnico→mental
- A_{opt} : Edad óptima para desarrollo físico

- σ : Ancho de la curva de desarrollo
- w_F, w_T, w_M : Pesos para cálculo de rating

3. Variables de control:

- $E = (E_F, E_T, E_M)$: Intensidad de entrenamiento por área (0-1)
- `lesion_activa`: Booleano que activa penalizaciones por lesión
- `fatiga`: Factor acumulativo (0-0.5) que reduce efectividad

4. Métricas de evaluación derivadas:

- `Rating_Final`: Rating proyectado al final de la simulación
- `Pico_Rating`: Valor máximo alcanzado durante la carrera
- `Edad_Pico`: Edad en la que se alcanza el máximo rating
- `Impacto_Lesion`: Porcentaje de pérdida por lesión grave
- `Mejora_Total`: Diferencia entre rating final e inicial

5. Resultados de optimización:

- `Entrenamiento_Optimo`: Combinación (E_F, E_T, E_M) que maximiza rating
- `Rating_Optimo`: Máximo rating alcanzable con entrenamiento óptimo
- `Error_Metodos`: Diferencia entre RK4 y Euler

6. Archivos y datasets generados:

- `resultados_5_casos_estudio.csv`: Tabla con resultados completos
- `reporte_final.txt`: Análisis textual detallado
- `dashboard_completo.png`: Visualización integrada
- `caso_estudio_*.png`: Gráficos individuales por jugador

7. Insights del sistema:

- **Sinergias identificadas:** El desarrollo físico potencia el técnico (γ_{FT}), y la combinación físico-técnico potencia el mental (δ)
- **Ventana óptima:** Desarrollo máximo ocurre alrededor de $A_{opt} \pm \sigma$ años
- **Resiliencia mental:** Menor impacto de lesiones en atributos mentales

- **Importancia del timing:** Resultados muy sensibles al momento de picos de entrenamiento

3. Modelos lineales

Regresión lineal

Se entrenó un modelo de regresión lineal múltiple utilizando variables originales y derivadas. En el primer entrenamiento se observó colinealidad significativa y desempeño limitado ($RMSE \approx 2.98$, $R^2 \approx 0.75$). En el segundo entrenamiento, tras limpieza y regularización, se alcanzó $RMSE \approx 1.82$ y $R^2 \approx 0.91$, superando los objetivos.

Regresión logística

Se implementó un modelo One-vs-Rest para clasificación de posiciones (Defensa, Medio, Atacante), usando variables derivadas y físicas. La división train/test estratificada y balanceo de clases permitió evaluar desempeño con exactitud estable y matriz de confusión balanceada.

Resultados

Primer Modelo

- **RMSE:** 2.98
- **R^2 :** 0.75
- **Observaciones:** Multicolinealidad alta, variables clave: *reactions*, *ball_control*, *strength*.
- **Conclusión:** No se alcanzaron los objetivos; se estableció una línea base y se identificaron mejoras necesarias en preprocesamiento.

Segundo Modelo

- **RMSE:** 1.82
- **R^2 :** 0.91
- **Observaciones:** Limpieza de datos, interacciones polinomiales, regularización L2.
- **Conclusión:** Objetivos cumplidos; modelo robusto con buena generalización y capacidad predictiva.

4. Redes neuronales

Arquitecturas

Red 1 - Predicción de Potencial (Regresión):

- **Capacidad de entrada:** 20 características
- **Arquitectura:** [20, 256, 128, 64, 1]
- **Activaciones:** ReLU en capas ocultas, lineal en salida
- **Parámetros:** $20 \times 256 + 256 \times 128 + 128 \times 64 + 64 \times 1 = 73,728$ pesos

Red 2 - Clasificación de Perfil (Clasificación multiclase):

- **Capacidad de entrada:** 15 características
- **Arquitectura:** [15, 256, 128, 6]
- **Activaciones:** ReLU en capas ocultas, Softmax en salida
- **Clases:** 6 perfiles de jugador
- **Parámetros:** $15 \times 256 + 256 \times 128 + 128 \times 6 = 49,664$ pesos

Parámetros comunes a ambas redes:

- **Tasa de aprendizaje:** 0.001
- **Regularización L2:** $\lambda = 0.01$
- **Batch size:** 64
- **Épocas:** 500
- **Inicialización:** Xavier/Glorot

Entrenamiento

Proceso de entrenamiento Red 1 (Potencial):

- **Costo inicial:** 150.1756 (alta variabilidad)
- **Costo final:** 0.0095 (convergencia estable)
- **Reducción de costo:** 99.99% durante entrenamiento
- **Validación:** Costo final 0.0216 (ligeramente mayor, sin sobreajuste)
- **Curva de aprendizaje:** Convergencia rápida entre épocas 100-400

Proceso de entrenamiento Red 2 (Perfil):

- **Costo inicial:** 1.7691 (entropía cruzada)

- **Costo final:** 0.5009 (reducción del 71.7%)
- **Accuracy validación:** Incremento de 18.81% a 78.26%
- **Curva de aprendizaje:** Mejora constante sin señales de sobreajuste

Validación Cruzada (5-Fold):

- **Red 1 - R² promedio:** 0.9992 ± 0.0001
- **Red 1 - RMSE promedio:** 0.1718 ± 0.0150
- **Red 2 - Accuracy promedio:** 0.7815 ± 0.0094
- **Red 2 - F1-Score promedio:** 0.7789 ± 0.0092
- **Consistencia:** Resultados estables entre folds

Evaluación

Métricas de rendimiento finales:

Red 1 - Regresión (test set):

- **MAE:** 0.3871 puntos (error absoluto promedio)
- **RMSE:** 0.4221 puntos (penaliza errores grandes)
- **R²:** 0.9951 (explica 99.51% de varianza)
- **Max Error:** 1.6352 puntos (peor predicción)
- **Errores > 5 puntos:** 0.00% (ningún error grave)

Red 2 - Clasificación (test set):

- **Accuracy:** 79.74% (precisión global)
- **Precision (weighted):** 79.30% (exactitud predicciones positivas)
- **Recall (weighted):** 79.74% (capacidad detectar casos reales)
- **F1-Score (weighted):** 79.44% (balance precisión/recall)
- **AUC-ROC:** 0.9716 (excelente discriminación)

Análisis por clase (Red 2):

- 1. Central Defender:** Mejor rendimiento (Precision: 90%, Recall: 94%)
- 2. Forward:** Alto rendimiento (Precision: 87%, Recall: 90%)

- 3. **Full Back:** Buen rendimiento (Precision: 77%, Recall: 82%)
- 4. **Attacking Midfielder:** Rendimiento moderado (Precision: 69%, Recall: 66%)
- 5. **Central Midfielder:** Rendimiento moderado (Precision: 66%, Recall: 64%)
- 6. **Defensive Midfielder:** Menor rendimiento (Precision: 68%, Recall: 57%)

Comparación con modelos baseline:

Métrica	Baseline	Modelo	Mejora
-			
Red 1 - MAE	4.8756	0.3871	92.1%
Red 1 - R²	0.0000	0.9951	Infinito
Red 2 - Accuracy	24.19%	79.74%	229.6%
Red 2 - F1-Score	9.42%	79.44%	742.9%

Análisis de importancia de características:

Red 1 (Regresión):

- 1. **free_kick_accuracy:** Importancia 4.55 (negativa)
- 2. **weight:** Importancia 4.55 (negativa)
- 3. **height:** Importancia 4.54 (negativa)
- 4. **long_passing:** Importancia 4.54 (negativa)
- 5. **heading_accuracy:** Importancia 4.53 (negativa)

Red 2 (Clasificación):

- 1. **defense_score:** Importancia 0.480 (más importante)
- 2. **score_tecnico:** Importancia 0.350
- 3. **speed_score:** Importancia 0.260
- 4. **attack_score:** Importancia 0.250
- 5. **score_fisico:** Importancia 0.200

DÍA 3 Sistema integrado

Demostración

Ejecución del sistema completo:

- Sistema ejecutado exitosamente sin errores
- 5 jugadores seleccionados aleatoriamente para análisis
- Todos los escenarios probados sin problemas
- Métodos RK4 y Euler implementados correctamente
- Factores de perturbación (lesiones, fatiga) integrados

Métricas de ejecución:

- **Tiempo de simulación:** Completado en tiempo razonable
- **Estabilidad numérica:** Sin divergencias ni errores de cálculo
- **Consistencia:** Resultados reproducibles con semilla random_state=42

Validaciones realizadas:

1. **Comparación de métodos de integración:** RK4 vs Euler
2. **Análisis de sensibilidad:** Variación de parámetros alpha_F
3. **Evaluación de escenarios:** 5 perfiles de desarrollo
4. **Impacto de factores externos:** Lesiones y fatiga
5. **Optimización de entrenamiento:** 6 regímenes diferentes

Casos de estudio

Caso 1: Dieter van Tornhout

- **Edad:** 26 años
- **Rating** inicial: 63.0
- **Perfil:** Score físico alto (65.4), técnico bajo (48.6), mental medio (60.4)
- **Mejor escenario:** joven_promesa
- **Rating final proyectado:** 95.0
- **Impacto de lesiones:** 0.0%
- **Entrenamiento óptimo:** 0.8/0.6/0.7 (F/T/M)

Caso 2: Francesco Scardina

- **Edad:** 30 años
- **Rating inicial:** 63.0
- **Perfil:** Score físico medio (61.9), técnico bajo (36.8), mental bajo (43.4)
- **Mejor escenario:** joven_promesa
- **Rating final proyectado:** 95.0
- **Impacto de lesiones:** 0.0%
- **Entrenamiento óptimo:** 0.8/0.6/0.7 (F/T/M)

Caso 3: David Amoo

- **Edad:** 25 años
- **Rating inicial:** 66.0
- **Perfil:** Score físico muy alto (83.0), técnico medio (64.9), mental medio (54.4)
- **Mejor escenario:** joven_promesa
- **Rating final proyectado:** 95.0
- **Impacto de lesiones:** 0.0%
- **Entrenamiento óptimo:** 0.8/0.6/0.7 (F/T/M)

Caso 4: Robert Klaasen

- **Edad:** 22 años
- **Rating inicial:** 64.0
- **Perfil:** Score físico medio (61.1), técnico alto (64.7), mental alto (63.9)
- **Mejor escenario:** joven_promesa
- **Rating final proyectado:** 95.0
- **Impacto de lesiones:** 0.0%
- **Entrenamiento óptimo:** 0.8/0.6/0.7 (F/T/M)

Caso 5: Issa Cissokho

- **Edad:** 31 años

- **Rating inicial:** 74.0
- **Perfil:** Score físico alto (79.5), técnico alto (69.9), mental alto (63.8)
- **Mejor escenario:** joven_promesa
- **Rating final proyectado:** 95.0
- **Impacto de lesiones:** 0.0%
- **Entrenamiento óptimo:** 0.8/0.6/0.7 (F/T/M)

ANÁLISIS DE RESULTADOS

Hallazgos clave:

1. Consistencia en resultados:

- Todos los jugadores alcanzan rating máximo de 95.0
- Métodos RK4 y Euler producen resultados idénticos
- Mínima variación entre escenarios diferentes

2. Limitaciones identificadas:

- **Valor límite artificial:** El sistema alcanza siempre 95.0 debido a restricciones de clipping
- **Falta de diferenciación:** Parámetros pueden estar sobredimensionados
- **Impacto nulo de lesiones:** Reducción de efectividad insuficiente

3. Recomendaciones de mejora:

- Ajustar parámetros para mayor realismo en ratings finales
- Incrementar impacto de lesiones y fatiga
- Implementar degradación por edad más pronunciada
- Añadir aleatoriedad controlada en simulaciones

Métricas agregadas:

	Métrica	Valor	

Mejora promedio	29.0 puntos	
Impacto promedio de lesiones	0.0%	
Escenario más efectivo	joven_promesa	
Rating promedio inicia	66.0	
Rating promedio final	95.0	
Edad promedio	26.8 años	

Optimización de entrenamiento:

Mejor régimen encontrado: Fisico intenso

- Entrenamiento físico: 0.9 (90% intensidad)
- Entrenamiento técnico: 0.6 (60% intensidad)
- Entrenamiento mental: 0.5 (50% intensidad)
- Rating máximo alcanzable: 95.0

Comparación de métodos:

- RK4 vs Euler: Diferencia 0.0 puntos, error relativo 0.0%
- Precisión: Ambos métodos convergen a mismos resultados
- Estabilidad: Sistema numéricamente estable

Archivos generados:

1. **resultados_5_casos_estudio.csv** - Datos tabulares completos
2. **reporte_final.txt** - Análisis textual detallado
3. **dashboard_completo.png** - Visualización integrada
4. **5 gráficos individuales (caso_estudio_X_Nombre.png)** - Análisis por jugador

6. Conclusión

Lecciones aprendidas

1. **Integración de múltiples técnicas de ML:** El proyecto demostró que es posible combinar exitosamente diferentes enfoques de aprendizaje automático (redes neuronales, sistemas dinámicos, análisis estadístico) en una solución cohesiva para análisis deportivos.

- 2. Importancia del preprocesamiento de datos:** La calidad de los resultados está directamente relacionada con la calidad del preprocesamiento. La limpieza, normalización y derivación de variables fueron fundamentales para el éxito del modelo.
- 3. Sistemas dinámicos para modelado temporal:** Los sistemas de ecuaciones diferenciales ofrecen una forma poderosa de modelar la evolución temporal de atributos complejos, como el desarrollo de un futbolista a lo largo de su carrera.
- 4. Validación rigurosa es esencial:** La implementación de validación cruzada, comparación con baselines y múltiples métricas de evaluación permitió una comprensión más profunda del rendimiento real de los modelos.
- 5. Interpretabilidad vs rendimiento:** Encontrar el equilibrio entre modelos complejos de alto rendimiento y modelos interpretables fue un desafío constante. Las técnicas de importancia de características ayudaron a puentear esta brecha.
- 6. Consideraciones prácticas en deportes:** Factores como lesiones, fatiga y edad tienen impactos no lineales que deben modelarse cuidadosamente para predicciones realistas.
- 7. Colaboración interdisciplinaria:** El proyecto benefició significativamente de la combinación de conocimientos en matemáticas, programación, estadística y comprensión del fútbol.

Trabajo futuro

1. Refinamiento del modelo dinámico:

- Incorporar más datos históricos de jugadores reales para calibrar mejor los parámetros
- Añadir factores adicionales como cambios de equipo, entrenadores y sistemas tácticos
- Implementar mecanismos de retroalimentación más sofisticados entre variables

2. Expansión del sistema de predicción:

- Incluir predicción de transferencias y valores de mercado
- Desarrollar modelos para predicción de rendimiento en partidos específicos
- Crear sistemas de recomendación para scouting y desarrollo juvenil

3. Mejoras técnicas:

- Implementar redes neuronales más avanzadas (LSTM, Transformers) para secuencias temporales
- Integrar técnicas de ensemble learning para mayor robustez
- Desarrollar una interfaz web interactiva para usuarios no técnicos

4. Validación con datos reales:

- Seguimiento longitudinal de las predicciones realizadas
- Comparación con trayectorias reales de jugadores profesionales
- Ajuste continuo de modelos basado en nuevos datos

5. Escalabilidad y aplicaciones:

- Extender el sistema a otros deportes (baloncesto, tenis, etc.)
- Desarrollar versiones para equipos juveniles y femeninos
- Crear APIs para integración con sistemas existentes de clubes profesionales

6. Investigación académica:

- Publicación de hallazgos metodológicos en revistas especializadas
- Colaboración con instituciones deportivas para validación empírica
- Desarrollo de nuevos algoritmos específicos para análisis deportivo

7. Consideraciones éticas:

- Establecer protocolos para uso ético de datos de jugadores
- Desarrollar sistemas transparentes y explicables
- Considerar implicaciones en contrataciones y desarrollo de carrera

RESULTADOS DIA 1




Figura 1 : Gráficos de Modelos Lineales

Interpretacion de graficos:

Primer gráfico

QQ-Plot de residuos:

- Muestra que los residuos se desvían claramente de la línea teórica (línea recta), especialmente en las colas.
- Esto sugiere que los residuos no siguen una distribución normal, lo cual viola uno de los supuestos clave de muchos modelos lineales.

- Los puntos en los extremos (colas) están más dispersos, indicando la presencia de valores atípicos o una distribución con colas más pesadas que la normal.

Histograma de residuos:

- La distribución de los residuos es asimétrica, con una cola hacia la derecha (valores positivos más grandes).
- Hay una concentración grande de residuos cerca de cero, pero también se observan valores extremos positivos (hasta 20).
- Esto confirma la no normalidad y la posible presencia de heterocedasticidad (variabilidad no constante).




Figura 2 : Gráficos de Modelos Lineales

Segundo gráfico

Gráfico de residuos vs valores predichos:

- Los residuos parecen aumentar su dispersión a medida que aumentan los valores predichos (forma de “abanico” o “cono”).
- Esto indica heterocedasticidad: la varianza de los errores no es constante, lo cual es otro supuesto violado en modelos lineales clásicos.
- Además, se observa cierta estructura en los residuos (no son aleatorios alrededor de cero), lo que sugiere que el modelo podría estar omitiendo variables relevantes o relaciones no lineales.

Interpretación global:

El modelo tiene problemas de supuestos: no normalidad, heterocedasticidad y posiblemente especificación incorrecta.

INTERPRETACIÓN DE RESULTADOS DE LA TERMINAL

PRIMER ENTRENAMIENTO:

1. Datos iniciales y limpieza

Se cargaron 11,060 jugadores con 44 características.

Después de la limpieza y tratamiento de outliers, quedaron 8,649 jugadores (se eliminaron ~22%).

2. Modelo de Regresión Lineal Múltiple (predicción de overall rating)

R^2 promedio (validación cruzada): 0.7510 → excelente capacidad predictiva.

RMSE promedio: 2.9757 → el error típico de predicción es de ~3 puntos en el overall.

MAE promedio: 2.3332 → error absoluto promedio de ~2.33 puntos.

Variables más importantes:

reactions (25.17%)
ball_control (22.83%)
strength (10.06%)
short_passing (8.71%)

Multicolinealidad grave detectada:

VIF muy altos (ej. ball_control = 265), lo que afecta la estabilidad de los coeficientes.

3. Modelo de Regresión Logística (clasificación de posición)

Accuracy: 0.6333 → desempeño moderado.

Clases: Defensa (45.2%), Medio (31.2%), Atacante (23.6%).

Jugadores híbridos detectados: 307 (42.6%) → muchos jugadores no encajan claramente en una sola posición.

F1-score por clase:

Defensa: 0.689

Medio: 0.649

Atacante: 0.550 (el peor clasificado)

4. Validación estadística (problemas detectados)

Residuos NO normales (p-valor ≈ 0).

Heterocedasticidad detectada (varianza no constante en los errores).

Esto confirma que el modelo lineal viola supuestos, aunque predice bien.

SEGUNDO ENTRENAMIENTO

1. Mejora en el modelo de regresión lineal

- Primer modelo:

- R^2 : 0.7510

- RMSE: 2.9757

- Segundo modelo:

- R^2 : 0.9063 (mejora de +0.15)

- RMSE: 1.8226 (error reducido en ~1.15 puntos)

El modelo mejorado explica el 90.6% de la variabilidad y es mucho más preciso.

2. Cambio en las variables utilizadas

- **Original:** 15 variables específicas (aceleración, sprint_speed, etc.).

- **Mejorado:** Se usan scores compuestos ('score_fisico', 'score_tecnico', 'score_mental') e interacciones entre variables.

Las interacciones tuvieron coeficientes ~ 0 , pero los scores fueron claves.

3. Multicolinealidad aún presente pero diferente

- **Original:** VIF altísimos (ej. 265 en 'ball_control').

- **Mejorado:** VIF aún altos, con valores 'inf' en varias variables (división por cero), lo que indica colinealidad perfecta en algunos casos.

4. Empeoramiento GRAVE en la regresión logística

- Original:

- Accuracy: 0.6333

- Matriz de confusión balanceada

- Mejorado:

- Accuracy: 0.418 (caída fuerte)

- Clase 3 (Atacante) con 0% de aciertos

- Matriz de confusión muestra que todos los atacantes fueron mal clasificados

RESUMEN DE LA MEJORA

Aspecto	Original	Mejorado	Cambio
R ² regresión	0.7510	0.9063	Mejoría grande
RMSE	2.9757	1.8226	Error reducido

Arreglos para obtener las métricas R² y RMSE

Estandarización de variables

Apliqué normalización (media 0, varianza 1) a las variables explicativas antes de entrenar el modelo. Esto evitó problemas de overflow en el descenso de gradiente y mejoró la convergencia.

Selección y agregación de variables

Reorganice las variables originales en tres scores compuestos:

- score_fisico
- score_tecnico
- score_mental

Esto redujo el ruido y ayudó a capturar relaciones más relevantes con overall_rating.

Modelo con regularización

Implementé regresión lineal con regularización L2 (ridge).

Probé distintos valores y el mejor fue:

- alpha = 0.005
- lambda = 10

Búsqueda de hiperparámetros

Hice un barrido controlado de alpha y lambda.

Me quedé con la configuración que mejor funcionó en promedio, no solo en un fold.

Validación cruzada

Usé K-Fold Cross Validation (k=5) para evaluar:

- RMSE
- R²
- MAE

Esto garantiza que el modelo generaliza y no está sobreajustado.

RESULTADOS DIA 2




Figura : Gráfico de acierto y errores en el entrenamiento de las redes neuronales




Figura : Gráfico de importancia de variables en la red de regresión




Figura : Gráfico de importancia de variables en la red de clasificación

TERMINAL

RED 1: Prediccion de Potencial Maximo

ENTRENANDO RED NEURONAL - PREDICCIÓN DE POTENCIAL

Epoca 0: Costo entrenamiento = 95.6672, Costo validacion = 97.7722

Epoca 100: Costo entrenamiento = 0.0489, Costo validacion = 0.0763

Epoca 200: Costo entrenamiento = 0.0866, Costo validacion = 0.0995

Epoca 300: Costo entrenamiento = 0.0080, Costo validacion = 0.0213

Epoca 400: Costo entrenamiento = 0.0092, Costo validacion = 0.0212

Entrenamiento completado

RED 2: Clasificación de Perfil de Jugador (7 CLASES)

Distribución de perfiles (7 clases requeridas):

Central Defender: 2090 jugadores (24.2%)

Forward: 2011 jugadores (23.3%)

Full Back: 1435 jugadores (16.6%)

Attacking Midfielder: 1116 jugadores (12.9%)

Defensive Midfielder: 1003 jugadores (11.6%)

Central Midfielder: 993 jugadores (11.5%)

ADVERTENCIA: Solo 0 porteros encontrados. Considerar ajustar el umbral para identificar porteros.

ENTRENANDO RED NEURONAL - CLASIFICACION DE PERFIL

Epoca 0: Costo entrenamiento = 1.7396, Costo validacion = 1.7435, Accuracy validacion = 0.2159

Epoca 100: Costo entrenamiento = 0.6728, Costo validacion = 0.6930, Accuracy validacion = 0.7263

Epoca 200: Costo entrenamiento = 0.5618, Costo validacion = 0.5872, Accuracy validacion = 0.7602

Epoca 300: Costo entrenamiento = 0.5181, Costo validacion = 0.5468, Accuracy validacion = 0.7803

Early stopping en epoca 361 Entrenamiento completado

2. VALIDACION CRUZADA (5-FOLD)

Validación Cruzada - Red 1 (Regresión):

Fold 1: R2 = 0.9984, RMSE = 0.2408

Fold 2: R2 = 0.9990, RMSE = 0.1914

Fold 3: R2 = 0.9994, RMSE = 0.1513

Fold 4: R2 = 0.9988, RMSE = 0.2092

Fold 5: R2 = 0.9982, RMSE = 0.2529

Promedio 5-fold - Red 1:

MAE: 0.1620

RMSE: 0.2091

R2: 0.9988

Max Error: 1.4656

Distribución de perfiles (7 clases requeridas):

Central Defender: 2090 jugadores (24.2%)

Forward: 2011 jugadores (23.3%)

Full Back: 1435 jugadores (16.6%)

Attacking Midfielder: 1116 jugadores (12.9%)

Defensive Midfielder: 1003 jugadores (11.6%)

Central Midfielder: 993 jugadores (11.5%)

ADVERTENCIA: Solo 0 porteros encontrados. Considerar ajustar el umbral para identificar porteros.

Clases encontradas: ['Attacking Midfielder' 'Central Defender' 'Central Midfielder' 'Defensive Midfielder' 'Forward' 'Full Back']

Numero de clases: 6

Validacion Cruzada - Red 2 (Clasificacion):

Fold 1: Accuracy = 0.7642, F1 = 0.7621

Fold 2: Accuracy = 0.7688, F1 = 0.7656

Fold 3: Accuracy = 0.7717, F1 = 0.7645

Fold 4: Accuracy = 0.7727, F1 = 0.7699

Fold 5: Accuracy = 0.7831, F1 = 0.7811

Promedio 5-fold - Red 2:

Accuracy: 0.7721

Precision: 0.7691

Recall: 0.7721

F1-Score: 0.7686

AUC-ROC: 0.9665

3. ANALISIS COMPLETO DE ERRORES

Media de residuos: -0.0795

Desviacion estandar: 0.1184

Residuo maximo: 0.8836

Porcentaje errores > 1

punto: 0.00%

Porcentaje errores > 2

puntos: 0.00%

ANALISIS POR RANGOS DE POTENCIAL: 0-60:

MAE=0.2275, RMSE=0.3029, n=21 60-65: MAE=0.1277, RMSE=0.1927, n=165 65-70:

MAE=0.1011, RMSE=0.1328, n=360 70-75: MAE=0.0979, RMSE=0.1240, n=396 75-80:

MAE=0.1019, RMSE=0.1272, n=243 80-85: MAE=0.0972, RMSE=0.1156, n=87 85-90:

MAE=0.1255, RMSE=0.1764, n=26

RED 2 - ANALISIS DE CLASIFICACION:

-

MATRIZ DE CONFUSION: (Fila: Real, Columna: Prediccion)

	Attac	Centr	Centr	Defen	Forwa	Full
Attacking Mi 108		27	26	6	0	0
Central Defe 295		2	11	6	0	0
Central Midf 26		1	99	9	8	6
Defensive Mi 1		23	10	85	31	0
Forward 18		6	2	273	3	0
Full Back 2		10	8	18	4	174

METRICAS POR CLASE:

Attacking Midfielder:

Precision=0.697,

Recall=0.647,

F1=0.671

Central Defender:

Precision=0.897,

Recall=0.939,

F1=0.918

Central Midfielder:

Precision=0.651,

Recall=0.664,

F1=0.658

Defensive Midfielder:

Precision=0.680,

Recall=0.567,

F1=0.618

Forward:

Precision=0.878,

Recall=0.904,

F1=0.891

Full Back:

Precision=0.770,

Recall=0.806,

F1=0.787

ERRORES SISTEMATICOS (Top 10):

Defensive Midfielder -> Full Back: 31 casos

Attacking Midfielder -> Central Midfielder: 27 casos

Attacking Midfielder -> Forward: 26 casos

Central Midfielder -> Attacking Midfielder: 26 casos

Defensive Midfielder -> Central Defender: 23 casos

Forward -> Attacking Midfielder: 18 casos

Full Back -> Defensive Midfielder: 18 casos

Central Defender -> Defensive Midfielder: 11 casos

Defensive Midfielder -> Central Midfielder: 10 casos

Full Back -> Central Defender: 10 casos

ANALISIS DE CONFIANZA:

Confianza promedio: 0.770

Confianza en aciertos: 0.815

Confianza en errores: 0.596 4.

ANALISIS DE IMPORTANCIA DE CARACTERISTICAS

TOP 10 CARACTERISTICAS MAS IMPORTANTES:

1. overall_rating: 6.321875

2. potential_diff: 3.420514

3. score_tecnico: 0.206104

4. attack_score: 0.145217

5. dribbling: 0.129636
6. finishing: 0.083937
7. short_passing: 0.075711
8. defense_score: 0.048173
9. score_mental: 0.042634
10. volleys: 0.037247

ANALISIS DE IMPORTANCIA DE CARACTERISTICAS

TOP 10 CARACTERISTICAS MAS IMPORTANTES:

1. defense_score: 0.310000
2. score_tecnico: 0.240000
3. stamina: 0.110000
4. attack_score: 0.100000
5. speed_score: 0.095000
6. overall_rating: 0.070000
7. score_mental: 0.065000
8. score_fisico: 0.060000
9. reactions: 0.040000
10. height: 0.025000

5. COMPARACION CON MODELOS BASELINE

RED 1 - Regresion:

Baseline MAE: 4.8756

Modelo MAE: 0.1059

Mejora: 97.8%

RED 2 - Clasificacion:

Baseline Accuracy: 0.2419

Modelo Accuracy: 0.7966

Mejora: 229.3%

REPORTE FINAL - DIA 2: REDES NEURONALES

RESULTADOS PRINCIPALES: -

RED 1 (Regresion):

R² Test: 0.9994

MAE Test: 0.1059

R² CV Promedio: 0.9988

RED 2 (Clasificacion - 6 clases):

Accuracy Test: 0.7966

F1-Score Test: 0.7935

AUC-ROC Test: 0.9702

Accuracy CV Promedio: 0.7721

NOTA: Red 2 encontro 6 clases en lugar de

7. Esto puede deberse a que no hay suficientes porteros en el dataset. Se ha ajustado la arquitectura a $\{\text{len}(\text{le2.classes_})\}$ neuronas de salida.

INTERPRETACIÓN

1. $R^2 = 0.9994$

Significado: Mide cuánta variabilidad de la variable objetivo (potencial) es explicada por el modelo.

- 0.9994 = 99.94% de la variabilidad del potencial es explicada por las características
- Interpretación: EXCELENTE - El modelo explica prácticamente toda la variación
- Comparativa:
 - 1.0 = Perfecto (imposible en datos reales)
 - 0.9+ = Excelente
 - 0.8-0.9 = Muy bueno
 - 0.7-0.8 = Bueno
 - <0.5 = Deficiente

2. MAE = 0.1059

Significado: Error absoluto medio - Diferencia promedio entre predicción y valor real.

- 0.106 puntos de error promedio
- Interpretación: MUY BAJO ERROR - En una escala de 0-100, el error promedio es de solo 0.1 puntos
- Ejemplo: Si un jugador tiene potencial 85, el modelo predice entre 84.9 y 85.1

3. RMSE = 0.1509

Significado: Raíz del error cuadrático medio - Penaliza más los errores grandes.

- 0.151 puntos (ligeramente mayor que MAE)
- Interpretación: Los errores grandes son muy raros
- Ventaja: Más sensible a outliers (pero en este caso no hay)

4. Error Máximo = 0.8836

Significado: El peor error cometido por el modelo.

- Menos de 1 punto en el peor caso
- Interpretación: EXCELENTE - Incluso la peor predicción está dentro de 1 punto

RED 2: CLASIFICACIÓN DE PERFIL

MÉTRICAS DE CLASIFICACIÓN:

1. Accuracy = 79.66%

Significado: Porcentaje total de predicciones correctas.

- 79.66% de los jugadores clasificados correctamente
- Interpretación: MUY BUENO para 6 clases
- Contexto:
 - 16.67% = Aleatorio (1/6)
 - 79.66% = 4.8 veces mejor que aleatorio

2. Precision = 79.25%

Significado: De los predichos como clase X, ¿cuántos realmente son X?

- Ejemplo: Si dice "100 son Defensas Centrales", el 79.25% realmente lo son
- Interpretación: ALTA PRECISIÓN - Pocos falsos positivos

3. Recall = 79.66%

Significado: De los reales de clase X, ¿cuántos identificó correctamente?

- Ejemplo: De 100 Defensas Centrales reales, identifica 79.66
- Interpretación: BUEN RECUERDO - Pocos falsos negativos

4. F1-Score = 79.35%

Significado: Media armónica entre Precision y Recall.

- Balance entre precisión y cobertura
- Interpretación: EXCELENTE BALANCE - No sacrifica una métrica por otra

5. AUC-ROC = 0.9702

Significado: Capacidad del modelo para distinguir entre clases.

- 0.9702 en escala 0-1
- Interpretación: EXCELENTE DISCRIMINACIÓN
 - 1.0 = Perfecta discriminación
 - 0.9+ = Excelente
 - 0.8-0.9 = Buena
 - 0.7-0.8 = Aceptable
 - <0.7 = Deficiente

ANÁLISIS POR CLASE:

MEJORES CLASES:

1. Central Defender (Defensa Central):
 - Precision: 89.7%
 - Recall: 93.9%
 - F1: 91.8%
 - Interpretación: EXCELENTE - Fácil de identificar
2. Forward (Delantero):
 - Precision: 87.8%

- Recall: 90.4%
- F1: 89.1%
- Interpretación: MUY BUENO - Características distintivas

CLASES MÁS DIFÍCILES:

1. Defensive Midfielder (Medio Defensivo):
 - Precision: 68.0%
 - Recall: 56.7%
 - F1: 61.8%
 - Problema: Se confunde con Full Back (31 casos)
2. Attacking Midfielder (Medio Ofensivo):
 - Precision: 69.7%
 - Recall: 64.7%
 - F1: 67.1%
 - Problema: Se confunde con Central Midfielder

VALIDACIÓN CRUZADA (CONSISTENCIA)

Red 1 - 5-Fold:

- R^2 promedio: 0.9988 (muy estable entre folds)
- MAE promedio: 0.1620 (ligeramente mayor que en test)
- Interpretación: Modelo NO está overfitted, generaliza bien

Red 2 - 5-Fold:

- Accuracy promedio: 77.21% (vs 79.66% en test)
- Diferencia de 2.45% - EXCELENTE CONSISTENCIA

Interpretación: Modelo ROBUSTO, no memoriza datos

RESULTADOS DIA 3




Figura : Gráfico de Análisis de David Amoo




Figura : Gráfico de Análisis de Dieter van Tornhout




Figura : Gráfico de Análisis de Francesco Scardina

ANÁLISIS COMPLETO: Issa Cissokho
Edad: 31 años | Rating Inicial: 74.0 | Mejor Escenario: joven_promesa




Figura : Gráfico de Análisis de Issa Cissokho

ANÁLISIS COMPLETO: Robert Klaasen
Edad: 22 años | Rating Inicial: 64.0 | Mejor Escenario: joven_promesa




Figura : Gráfico de Análisis de Robert Klaasen

TERMINAL

SISTEMA DE ANALISIS DINAMICO DE FUTBOLISTAS

DIA 3: INTEGRACIÓN COMPLETA

CASO 1: Dieter van Tornhout

=====

Edad: 26 años | Rating: 63.0

Fisico: 65.4 | Tecnico: 48.6 | Mental: 60.4

A. COMPARACION DE METODOS DE INTEGRACION:

RK4: Rating final = 83.6

Euler: Rating final = 83.6

Diferencia: 0.0

B. ANALISIS DE SENSIBILIDAD (α_F):

$\alpha_F=0.06$: Rating final=91.2

$\alpha_F=0.1$: Rating final=91.2

$\alpha_F=0.14$: Rating final=91.2

$\alpha_F=0.18$: Rating final=91.2

$\alpha_F=0.22$: Rating final=91.2

C. COMPARACION DE ESCENARIOS:

joven_promesa: Final=66.5, Pico=91.2 (edad 26.0)

late_bloomer: Final=77.2, Pico=91.2 (edad 26.0)

balanceado: Final=68.6, Pico=91.2 (edad 26.0)

early_bloomer: Final=64.3, Pico=91.2 (edad 26.0)

lento_seguro: Final=73.4, Pico=91.2 (edad 26.0)

D. IMPACTO DE LESIONES:

Sin lesion: 69.5

Con lesion: 48.6

Impacto: 30.0%

E. OPTIMIZACION DE ENTRENAMIENTO:

Mejor regimen: Fisico-Tecnico

Entrenamiento: EF=0.8, ET=0.6, EM=0.7

Rating optimo: 69.5

=====

CASO 2: Francesco Scardina

=====

Edad: 30 años | Rating: 63.0

Fisico: 61.9 | Tecnico: 36.8 | Mental: 43.4

A. COMPARACION DE METODOS DE INTEGRACION:

RK4: Rating final = 68.6

Euler: Rating final = 68.6

Diferencia: 0.0

B. ANALISIS DE SENSIBILIDAD (α_F):

$\alpha_F=0.06$: Rating final=78.0

$\alpha_F=0.1$: Rating final=78.0

$\alpha_F=0.14$: Rating final=78.0

$\alpha_F=0.18$: Rating final=78.2

$\alpha_F=0.22$: Rating final=78.7

C. COMPARACION DE ESCENARIOS:

joven_promesa: Final=60.4, Pico=88.0 (edad 30.0)

late_bloomer: Final=64.4, Pico=88.0 (edad 30.0)

balanceado: Final=62.4, Pico=88.0 (edad 30.0)

early_bloomer: Final=58.5, Pico=88.0 (edad 30.0)

lento_seguro: Final=63.2, Pico=88.0 (edad 30.0)

D. IMPACTO DE LESIONES:

Sin lesion: 63.4

Con lesion: 44.4

Impacto: 30.0%

E. OPTIMIZACION DE ENTRENAMIENTO:

Mejor regimen: Fisico-Tecnico

Entrenamiento: EF=0.8, ET=0.6, EM=0.7

Rating optimo: 63.4

CASO 3: David Amoo

Edad: 25 años | Rating: 66.0

Fisico: 83.0 | Tecnico: 64.9 | Mental: 54.4

A. COMPARACION DE METODOS DE INTEGRACION:

RK4: Rating final = 93.1

Euler: Rating final = 93.1

Diferencia: 0.0

B. ANALISIS DE SENSIBILIDAD (α_F):

$\alpha_F=0.06$: Rating final=95.0

$\alpha_F=0.1$: Rating final=95.0

$\alpha_F=0.14$: Rating final=95.0

$\alpha_F=0.18$: Rating final=95.0

$\alpha_F=0.22$: Rating final=95.0

C. COMPARACION DE ESCENARIOS:

joven_promesa: Final=68.0, Pico=95.0 (edad 25.0)

late_bloomer: Final=84.0, Pico=95.0 (edad 25.0)

balanceado: Final=70.2, Pico=95.0 (edad 25.0)

early_bloomer: Final=65.8, Pico=95.0 (edad 25.0)

lento_seguro: Final=78.9, Pico=95.0 (edad 25.0)

D. IMPACTO DE LESIONES:

Sin lesion: 71.4

Con lesion: 50.0

Impacto: 30.0%

E. OPTIMIZACION DE ENTRENAMIENTO:

Mejor regimen: Fisico-Intenso

Entrenamiento: EF=0.9, ET=0.5, EM=0.7

Rating optimo: 71.7

CASO 4: Robert Klaasen

Edad: 22 años | Rating: 64.0

Fisico: 61.1 | Tecnico: 64.7 | Mental: 63.9

A. COMPARACION DE METODOS DE INTEGRACION:

RK4: Rating final = 95.0

Euler: Rating final = 95.0

Diferencia: 0.0

B. ANALISIS DE SENSIBILIDAD (α_F):

$\alpha_F=0.06$: Rating final=95.0

$\alpha_F=0.1$: Rating final=95.0

$\alpha_F=0.14$: Rating final=95.0

$\alpha_F=0.18$: Rating final=95.0

$\alpha_F=0.22$: Rating final=95.0

C. COMPARACION DE ESCENARIOS:

joven_promesa: Final=77.1, Pico=95.0 (edad 22.0)

late_bloomer: Final=91.2, Pico=95.0 (edad 22.3)

balanceado: Final=83.6, Pico=95.0 (edad 22.1)

early_bloomer: Final=70.1, Pico=95.0 (edad 22.0)

lento_seguro: Final=91.2, Pico=95.0 (edad 22.1)

D. IMPACTO DE LESIONES:

Sin lesion: 95.0

Con lesion: 66.5

Impacto: 30.0

E. OPTIMIZACION DE ENTRENAMIENTO:

Mejor regimen: Fisico-Tecnico

Entrenamiento: EF=0.8, ET=0.6, EM=0.7

Rating optimo: 95.0

CASO 5: Issa Cissokho

Edad: 31 años | Rating: 74.0

Fisico: 79.5 | Tecnico: 69.9 | Mental: 63.8

A. COMPARACION DE METODOS DE INTEGRACION:

RK4: Rating final = 67.1

Euler: Rating final = 67.1

Diferencia: 0.0

B. ANALISIS DE SENSIBILIDAD (α_F):

$\alpha_F=0.06$: Rating final=78.0

$\alpha_F=0.1$: Rating final=78.0

$\alpha_F=0.14$: Rating final=78.0

$\alpha_F=0.18$: Rating final=78.0

alpha_F=0.22: Rating final=78.0

C. COMPARACION DE ESCENARIOS:

joven_promesa: Final=58.9, Pico=86.5 (edad 31.0)

late_bloomer: Final=62.7, Pico=86.5 (edad 31.0)

balanceado: Final=60.8, Pico=86.5 (edad 31.0)

early_bloomer: Final=57.0, Pico=86.5 (edad 31.0)

lento_seguro: Final=61.6, Pico=86.5 (edad 31.0)

D. IMPACTO DE LESIONES:

Sin lesion: 61.9

Con lesion: 43.4

Impacto: 30.0%

E. OPTIMIZACION DE ENTRENAMIENTO:

Mejor regimen: Fisico-Tecnico

Entrenamiento: EF=0.8, ET=0.6, EM=0.7

Rating optimo: 61.9

REPORTE FINAL - RESUMEN DE 5 CASOS DE ESTUDIO

TABLA DE RESULTADOS:

Jugador	Edad	Rating_Inicial	Mejor_Escenario	Rating_Final	Pico_Rating	Edad_Pico	Impacto_Lesion	Entrenamiento_Optimo	Regimen_Optimo
---------	------	----------------	-----------------	--------------	-------------	-----------	----------------	----------------------	----------------

Dieter van Tornhout	26	63.0	joven_promesa	83.570662	91.2	26.005479	30.0	0.8/0.6/0.7	Fisico-Tecnico
---------------------	----	------	---------------	-----------	------	-----------	------	-------------	----------------

Francesco Scardina	30	63.0	joven_promesa	68.626673	88.0	30.008219	30.0	0.8/0.6/0.7	Fisico-Tecnico
--------------------	----	------	---------------	-----------	------	-----------	------	-------------	----------------

David Amoo	25	66.0	joven_promesa	93.105205	95.0	25.008219	30.0	0.9/0.5/0.7	Fisico-Intenso
------------	----	------	---------------	-----------	------	-----------	------	-------------	----------------

Robert Klaasen	22	64.0	joven_promesa	95.000000	95.0	22.013699	30.0	0.8/0.6/0.7	Fisico-Tecnico
----------------	----	------	---------------	-----------	------	-----------	------	-------------	----------------

Issa Cissokho | 31 | 74.0 joven_promesa | 67.067073 | 86.5 31.000000 |
30.0 | 0.8/0.6/0.7 | Fisico-Tecnico

ESTADISTICAS GENERALES:

Mejora promedio: 15.5 puntos

Impacto promedio de lesiones: 30.0%

Escenario mas efectivo: joven_promesa

Distribucion de edades pico:

Edad promedio de pico: 26.8 años

Rango de edades pico: 22.0 - 31.0 años

DASHBOARD INTERACTIVO AUTOMATICO

EJECUTANDO DEMOSTRACION AUTOMATICA DE TODAS LAS FUNCIONALIDADES...

1. RESUMEN DE CASOS DE ESTUDIO:

Jugador	Edad	Rating_Inicial	Mejor_Escenario	Rating_Final	Pico_Rating	Impacto_Lesion
Dieter van Tornhout	26	63.0	joven_promesa	83.570662	91.2	30.0
Francesco Scardina	30	63.0	joven_promesa	68.626673	88.0	30.0
David Amoo	25	66.0	joven_promesa	93.105205	95.0	30.0
Robert Klaasen	22	64.0	joven_promesa	95.000000	95.0	30.0
Issa Cissokho	31	74.0	joven_promesa	67.067073	86.5	30.0

2. ANALISIS DEL JUGADOR CON MAYOR MEJORA:

Jugador: Robert Klaasen

Edad: 22 años | Rating inicial: 64.0

Mejor escenario: joven_promesa

Rating final: 95.0 | Pico: 95.0

Mejora: 31.0 puntos

Impacto lesion: 30.0%

3. COMPARACION DE METODOS DE INTEGRACION:

Simulando jugador promedio con ambos metodos (10 años):

RK4: Rating final = 75.3

Euler: Rating final = 75.3

Diferencia: 0.00 puntos

Error relativo: 0.0%

Conclusion: RK4 es 0.0 puntos mas preciso

4. SIMULACION DE IMPACTO DE LESIONES:

Caso: Jugador joven prometedor con lesion grave

A) Sin lesion (15 anios):

Rating final: 68.0

Pico de rating: 95.0 (edad 22.0)

Mejora total: -7.0 puntos

B) Con lesion grave (anios 4-5):

Rating final: 47.6

Pico de rating: 95.0 (edad 22.0)

Perdida permanente: 20.4 puntos

Porcentaje perdido: 30.0%

5. OPTIMIZACIÓN AVANZADA DE ENTRENAMIENTO:

Evaluando 6 regimenes de entrenamiento para desarrollo maximo:

Resultados (12 años de simulacion):

-

Fisico Intenso | Final: 71.7 | Pico: 95.0 | Edad pico: 24.0 | EF=0.9, ET=0.6, EM=0.5

Tecnico Intenso | Final: 71.7 | Pico: 95.0 | Edad pico: 24.0 | EF=0.6, ET=0.9, EM=0.5

Mental Intenso | Final: 71.7 | Pico: 95.0 | Edad pico: 24.0 | EF=0.5, ET=0.6, EM=0.9

Balanceado | Final: 71.7 | Pico: 95.0 | Edad pico: 24.0 | EF=0.7, ET=0.7, EM=0.7

Ofensivo | Final: 71.7 | Pico: 95.0 | Edad pico: 24.0 | EF=0.6, ET=0.8, EM=0.6

Defensivo | Final: 71.7 | Pico: 95.0 | Edad pico: 24.0 | EF=0.8, ET=0.5, EM=0.7

MEJOR REGIMEN ENCONTRADO:

Nombre: Fisico Intenso

Entrenamiento: EF=0.9, ET=0.6, EM=0.5

Rating maximo alcanzable: 71.7

Pico de rating: 95.0 (edad 24.0)

Mejora sobre inicial: 1.7 puntos

INTERPRETACIÓN DE RESULTADOS

1. EDAD ÓPTIMA DE DESARROLLO:

INSIGHT: La ventana de desarrollo óptimo es 22-27 años.

2. ESCENARIO MÁS EFECTIVO:

INSIGHT: La estrategia de **inversión temprana y agresiva** rinde mejores frutos a largo plazo.

3. IMPACTO DE LESIONES:

INSIGHT: Las lesiones causan **pérdidas permanentes** del 30% del potencial, independientemente del jugador.

4. ENTRENAMIENTO ÓPTIMO:

INSIGHT: El balance **60-40% físico-técnico** es la estrategia más efectiva para la mayoría.

ANÁLISIS TÉCNICO DE LOS MÉTODOS:

INTERPRETACIÓN:

- Para **sistemas suaves** como este, Euler es suficiente
- RK4 (más preciso matemáticamente) no agrega valor aquí
- **Conclusión:** Euler es **computacionalmente más eficiente** sin perder precisión

ANÁLISIS DE RIESGOS:

1. LESIONES - EL FACTOR CRÍTICO:

IMPLICACIONES:

- **Robert Klaasen:** Pasaría de 95.0 a 66.5
- **David Amoo:** Pasaría de 93.1 a 65.2
- **Conclusión:** Programas de prevención son CRÍTICOS

RECOMENDACIONES ESTRATÉGICAS:

PARA DIRECTIVOS/CLUBES:

1. **PRIORIDAD ABSOLUTA:**
 - **Robert Klaasen** - Inversión máxima, protección especial
 - **David Amoo** - Desarrollo agresivo
2. **POLÍTICA DE TRANSFERENCIAS:**
 - **COMPRAR:** Jugadores 22-25 años con rating >60
 - **VENDER:** Jugadores >28 años en pico de valor
 - **RENOVAR:** Jugadores <27 años clave
3. **PROTOCOLO DE SALUD:**
 - Inversión en **prevención de lesiones** (30% impacto)
 - Seguimiento médico intensivo

PARA CUERPO TÉCNICO:

1. **ENTRENAMIENTO PERSONALIZADO:**
 - **Klaasen/Amoo:** Físico-Técnico intensivo
 - **Van Tornhout:** Mantenimiento balanceado
 - **Scardina/Cissokho:** Roles específicos, menos minutos
2. **DESARROLLO TÁCTICO:**
 - Aprovechar **fortalezas físicas** de Amoo
 - Desarrollar **habilidades técnicas** en Klaasen

PARA ANALISTAS/DATOS:

1. **MONITOREO CONTINUO:**
 - Seguimiento mensual de **tendencias de desarrollo**
 - Alertas tempranas de **sobreentrenamiento/lesiones**
2. **MODELOS PREDICTIVOS:**
 - Extender análisis a **toda la plantilla**
 - Identificar **patrones de éxito/fracaso**