

1. Introducción y Objetivos

1.1 Problema de Negocio

El objetivo es predecir el precio de inmuebles utilizando sus características físicas, estructurales y geográficas. Este tipo de modelos permite a agentes inmobiliarios, inversionistas y empresas de valuación tomar mejores decisiones al momento de fijar precios, estimar costos, analizar oportunidades de inversión y comparar propiedades de manera objetiva.

1.2 Objetivos del Proyecto

- Realizar ingeniería de features mediante:
 - Limpieza de valores nulos
 - Detección y tratamiento de valores atípicos
 - Normalización de variables
 - Selección estadística de features
 - Construcción de features polinomiales (función base $\phi(X)$)
- Implementar un modelo de regresión lineal entrenado mediante descenso de gradiente.
- Evaluar el rendimiento mediante métricas habituales de regresión (MSE, RMSE, R^2).
- Validar el modelo usando K-Fold Cross Validation.
- Diseñar un pipeline moderno para producción que incluya monitoreo y retraining automático.

2. Ingeniería de Features

2.1 Preprocesamiento Básico

En el proyecto se completaron los siguientes pasos:

Manejo de valores nulos

Se eliminaron columnas cuyo porcentaje de NaN era del 100%.

Resultado:

Columnas eliminadas por NaN completo = []

Esto significa que el dataset estaba relativamente limpio.

Manejo de valores atípicos

Se aplicó un tratamiento basado en IQR o reglas definidas en el código.

Normalización

Las variables continuas se escalonaron correctamente antes del descenso de gradiente, garantizando:

- estabilidad numérica
- convergencia más rápida
- coeficientes interpretables

2.2 Selección de Features

La selección se basó en:

- análisis estadístico
- correlación lineal
- eliminación de columnas no informativas
- comparación del rendimiento del modelo con diferentes subconjuntos
- habitaciones: numero de habitaciones en la vivienda. Se espera que a mayor cantidad, mayor sea el precio.
- banos: numero de baños. Similar a habitaciones, influye en el valor de la propiedad.
- area_vivienda: area construida dentro de la casa. Una medida directa del tamaño habitable, clave para el precio.
- pisos: cantidad de pisos de la vivienda. Viviendas con mas pisos suelen tener mayor valor.
- vista: indicador de la calidad de la vista (por ejemplo, panoramica o no). Se incluyo porque puede aumentar significativamente el valor.
- grado: nivel de acabados o calidad de la construccion. Es un factor cualitativo que impacta en el precio.
- total_area: suma de area_arriba + area_base. Sirve como medida total de espacio util de la vivienda.
- area_lote_log: logaritmo del area del lote. Se aplica log para normalizar valores grandes y reducir sesgo en la regresion.
- piscina: indicador binario de piscina. Las viviendas con piscina suelen valer mas.

Razon de seleccion:

Se eligieron estas features porque representan las características principales que afectan directamente el precio de una propiedad. Se incluyeron medidas de tamaño, calidad, amenities y ubicacion (via clusters de zonas geograficas, aplicados previamente). La combinacion de features numericas, logaritmicas y binarias ayuda a estabilizar el entrenamiento y mejorar la capacidad predictiva del modelo lineal.

2.3 Features Polinomiales

Se utilizaron funciones base $\phi(X)$ con transformaciones polinomiales para mejorar la capacidad del modelo.

¿Es válido utilizar latitud y longitud?

Hay que tener mucho cuidado, ya que los valores tienen muchas variaciones, si se hace un ajuste riguroso de dichos datos, se pueden llegar a utilizar, ya que son datos que recaen sobre el cálculo del precio.

3. Entrenamiento con Descenso de Gradiente

Hiperparámetros utilizados:

- Tasa de aprendizaje (α): valor ajustado empíricamente para convergencia estable.
- Máximo de iteraciones: 1000 en resultados.
- Tolerancia (épsilon): 1×10^{-6}
- Regularización: L2 (Ridge) incluida para prevenir sobreajuste.

Resultados del entrenamiento:

Resultados:

Número de iteraciones: 1018

Costo final: 0.057926

El costo converge sin oscilaciones, lo que indica buen ajuste de α y regularización.

4. Métricas de Evaluación

Métricas:

- MSE Train: 0.11585
- MSE Test: 0.11767
- RMSE Test: 0.34304
- R^2 Test: 0.5747

Interpretación técnica

- El valor de R^2 aproximadamente 0.575 indica que el modelo explica 57% de la variabilidad del precio.
- No existe evidencia de sobreajuste:
 - train y test están casi iguales (solo 1.5% de diferencia).
- El modelo es estable, pero no tiene suficiente capacidad predictiva.

Interpretación para negocio

Un R^2 apeoximadamente 0.57 implica:

- El modelo puede apoyar decisiones preliminares.
- No es suficientemente preciso para valuación profesional.
- Requiere mejor ingeniería de features.

5. Validación Cruzada (K-Fold)

El modelo soporta K-Fold y en la ejecución final se aplico correctamente.

La metodología seguida fue:

1. Dividir dataset en K pliegues del mismo tamaño.
2. Para cada iteración:
 - entrenar en $K-1$ pliegues
 - validar en el pliegue restante
 - registrar métricas
3. Promediar resultados.

Esto permite detectar:

- varianza del modelo
- estabilidad
- sobreajuste no detectable con un solo Split

Resultados obtenidos por fold:

- Fold 1 - MSE: 0.1196, RMSE: 0.3459, R2: 0.5517
- Fold 2 - MSE: 0.1143, RMSE: 0.3381, R2: 0.6058
- Fold 3 - MSE: 0.1119, RMSE: 0.3346, R2: 0.5716
- Fold 4 - MSE: 0.1210, RMSE: 0.3478, R2: 0.5700
- Fold 5 - MSE: 0.1133, RMSE: 0.3366, R2: 0.6071

Resultados promedio K-Fold:

- MSE promedio: 0.1160
- RMSE promedio: 0.3406
- R2 promedio: 0.5812

6. Simulación de Puesta en Producción

6.1 Pipeline de Producción

Tu pipeline propuesto incluye:

- preprocesamiento automatizado
- selección de features
- normalización
- entrenamiento

- monitoreo
- retraining cuando el rendimiento se degrade

6.2 Monitoreo

Incluye:

- Drift de datos: comparar distribuciones nuevas vs entrenamiento
- Performance decay: activar retraining si MSE aumenta >10%
- Latencia: tiempo de respuesta <100 ms (fácil para un modelo lineal)

7. Experimentación y Resultados

7.1 Diseño Experimental

Se cubrieron los experimentos planificados:

Experimento	Objetivo
Features Lineales	Baseline inicial
Features Polinomiales	Mejorar la capacidad predictiva
Selección de Features	Determinar las más relevantes
Hiperparámetros	Optimizar α e iteraciones
K-Fold	Evaluar estabilidad

Resultados Finales

Los últimos resultados obtenidos fueron:

MSE Train: 0.11585

MSE Test : 0.11767

RMSE Test: 0.3430

R^2 Test : 0.5747

8. Análisis de Resultados Esperados

Según la rúbrica:

- $R^2 \geq 0.8$ = Excelente
- $0.6 \leq R^2 < 0.8$ = Bueno
- $R^2 < 0.6$ = Necesita mejora

El resultado (0.5747) cae justo debajo de 0.6:

Se requiere mayor ingeniería de features o un modelo más expresivo.

Posibles mejoras:

- más features polinomiales

- interacciones entre variables
- modelos no lineales
- control sobre features variados (precio,long,lat)

9. Conclusiones y Trabajo Futuro

Conclusiones

- El modelo implementado funciona correctamente y no presenta sobreajuste.
- La ingeniería de features fue clave para estabilizar el entrenamiento.
- Sin embargo, el modelo aún no logra una precisión adecuada para predicción profesional de precios.
- Los resultados muestran que las relaciones entre características y precio no son totalmente lineales, lo que limita el desempeño del modelo actual.

Trabajo Futuro

- Incorporar modelos no lineales.
- Aplicar hiperopt o grid search para optimizar hiperparámetros.
- Expandir el dataset o incluir variables externas (distancias, infraestructuras, etc.).
- Implementar una verificación de sobre ajuste de 30% entrenamiento, 30% testing, y 30% validación

Nota : K-Fold fue actualizado por IA, ya que presentaba errores que no se comprendían como arreglarlos, pero el código esta siendo analizado, para comprender que se esta haciendo