



UNIVERSIDAD
CATÓLICA
BOLIVIANA
COCHABAMBA

Departamento de Ciencias Exactas e Ingeniería

Carrera: Ingeniería en Sistemas

Simulaciones

Estudiantes:

Figueroa Chávez Mateo Gael

Ramirez Machicado Nataly

Copa Mejia Daho Fabio

Josue Junior Camacho Canaviri

Ostin Lisandro Colque Rivas

Docente: Mag. Rodriguez Estevez Victor Adolfo

Cochabamba – Bolivia

fecha 27/09/2025

MODELO PROPAGACIÓN DEL COVID 2019

PRIMER MODELO: Empírico Basado en Datos de Bolivia 2020

1) Explicación del Modelo

Este modelo no usa ecuaciones epidemiológicas clásicas (SIR/SEIR), sino una función empírica adaptada a la realidad de Bolivia en 2020.

- Se divide la curva en fases: inicio, crecimiento, meseta y descenso.
- Se ajustan los parámetros (pico, tasa de crecimiento, tasa de descenso) para que la curva generada se parezca lo más posible a los datos reales de contagios.

2) Explicación de las Funciones

- `covid_model_bolivia(days)`: genera la curva de casos diarios simulados en función de los días, usando funciones exponenciales y logísticas.
- `get_bolivia_real_data()`: devuelve hitos temporales y estadísticas clave de Bolivia en 2020 (primer caso, cuarentena, pico, total de casos, tasa de letalidad, etc.).
- `simulate_bolivia_2020()`: construye la línea de tiempo, aplica el modelo y ajusta la curva para que coincida con el total real de casos (160.000).
- `plot_bolivia_analysis()`: visualiza la curva, los hitos y las fases de la pandemia.
- `print_epidemiological_analysis()`: imprime un análisis narrativo sobre datos epidemiológicos y factores propios de Bolivia.
- `validate_with_real_world()`: compara acumulados mensuales modelados con los datos reales reportados.

3) Explicación del Código

- Define los parámetros del modelo (pico, fechas, tasas).
- Simula la curva día por día desde marzo hasta diciembre 2020.
- Ajusta los resultados para que el número total de casos coincida con los datos reales reportados.
- Gráfica y explica resultados.

4) Explicación de los Datos en Terminal

- Total de casos 2020: coincide con ~160.000.
- Pico máximo diario y su fecha: 1.702 casos (25 de julio).
- Hitos temporales: cuarentena, flexibilización, inicio de segunda ola.
- Características epidemiológicas: forma logística con meseta, crecimiento moderado, descenso lento.
- Factores específicos de Bolivia: altitud, estructura poblacional, medidas de contención, sistema de salud, movilidad urbano-rural.

DATOS PRINCIPALES:

Total de casos 2020: 160,000

Pico maximo diario: 1702 casos

Fecha del pico: 2020-07-25

Tasa de letalidad: 6.2%

R0 inicial: 2.5

R0 post-intervencion: 1.2

HITOS TEMPORALES:

Primer Caso: 2020-03-10

Cuarentena Inicio: 2020-03-22

Primer Pico: 2020-07-25

Cuarentena Flexibilizada: 2020-08-01

Segunda Ola Inicio: 2020-11-01

CARACTERISTICAS EPIDEMIOLOGICAS:

Curva de tipo logistico con meseta prolongada

Crecimiento moderado debido a medidas tempranas

Pico en julio-agosto (invierno boliviano)

Descenso lento con reactivacion hacia fin de año

Patron similar a otros países andinos

FACTORES ESPECIFICOS DE BOLIVIA:

Altitud variable afectando transmision

Estructura poblacional joven

Medidas de contencion tempranas pero variables

VALIDACION CON DATOS REALES REPORTADOS

Marzo 2020: 100 casos reportados

Abril 2020: 1,000 casos reportados

Mayo 2020: 5,000 casos reportados

Junio 2020: 20,000 casos reportados

Julio 2020: 45,000 casos reportados

Agosto 2020: 80,000 casos reportados


Diciembre 2020: 160,000 casos reportados

El modelo se ajusta a la progresion real reportada por

el Ministerio de Salud de Bolivia y organismos internacionales

5) Explicación de las Gráficas

- Se muestra la curva simulada (línea azul).
- Líneas verticales marcan hitos importantes (cuarentena, pico, segunda ola).
- Colores de fondo indican fases de la pandemia (inicio, crecimiento, meseta, descenso).
- Se anotan los valores en el punto del pico epidémico.



6) Interpretación de la Gráfica

La gráfica presentada muestra la evolución de los casos de COVID-19 en Bolivia desde el primer caso reportado el 12 de marzo de 2020. Se han utilizado diferentes colores y líneas para indicar varias fases de la pandemia, reflejando la dinámica de la enfermedad a lo largo del tiempo.

Elementos Clave de la Gráfica

- Eje X (Días desde el primer caso):
 - Representa el tiempo transcurrido desde el primer caso, con un rango que abarca más de 250 días.
- Eje Y (Casos activos):
 - Muestra la cantidad de casos activos en la población, que fluctúa a lo largo del tiempo.
- Línea Azul:
 - Indica el número de casos activos. Se observa un pico inicial significativo seguido de variaciones.

Fases Identificadas


1. Periodo Inicial (Zona Azul):
 - Periodo inicial con medidas restrictivas significativas. Se observa un aumento rápido en el número de casos.
2. Pico Epidémico (Línea Verde):
 - Se marca el punto donde los casos alcanzan su nivel más alto, indicando una fase crítica en la propagación del virus.
3. Flexibilización (Línea Amarilla):

- Se implementan medidas de flexibilización. Esto se refleja en una disminución gradual de los casos.
4. Cuarentena (Línea Roja):
 - Se observa un cambio en la tendencia baja, aunque con oscilaciones que indican posibles repuntes.
 5. Meseta y Descenso (Zona Rosada):
 - La gráfica muestra una meseta donde los casos se estabilizan, seguida de un descenso notable, señalando el control de la propagación del virus.

Tendencias: La gráfica indica que tras el pico epidémico, las medidas de control y flexibilización han llevado a una reducción en los casos activos.

Impacto de las Medidas: Las fases de cuarentena y flexibilización claramente influyen en la dinámica de los casos, sugiriendo que las medidas de salud pública son efectivas en el control de la enfermedad.

7) Gráfica Comparativa entre datos reales y datos simulados



METRICAS DE COMPARACION:

Error absoluto medio: 277.45 casos por día

Coefficiente de correlacion: 0.697

En la gráfica comparativa se muestra la interposición de los datos simulados con los datos reales obtenidos los cuales muestran que los datos simulados tienen un acercamiento aproximado con los datos reales, a pesar de ello en la gráfica se muestra que hay un margen de error de alrededor de 500 casos en el pico máximo (277.45 error medio) y con un desfase en cuanto a días (2 a 3 días de diferencia).

SEGUNDO MODELO: SEIR con `get_euler`

1) Explicación de los Datos Obtenidos

- El modelo SEIR divide a la población en 4 compartimentos:
 - S (Susceptibles),
 - E (Expuestos, infectados pero aún no contagian),
 - I (Infectados que contagian),
 - R (Recuperados).

```
COMPARACION METRICAS - COVID-19 BOLIVIA 2020

Fecha pico real (dia 135): 1167 casos

Fecha pico modelo (dia 162): 193986 casos

Error en fecha del pico: 27 dias

Error en magnitud del pico: 192819 casos
```

- Se resolvió con el método de integración numérica Runge-Kutta 4 (implementado en la función `get_euler`).

Fecha pico real: día 135 → 1167 casos


Fecha pico SEIR: día 162 → 193986 casos

Error en fecha del pico: 27 días

Error en magnitud: 192.819 casos

- El modelo SEIR sobreestima enormemente el pico (más de 190 mil en un solo día, frente a ~1.100 reales).
- Además, el pico se retrasa casi un mes.
- Esto ocurre porque usamos parámetros generales (β , σ , γ) sin calibrar los datos de Bolivia.

2) Explicación de las gráficas



3) Interpretación de la gráfica

Elementos Clave de la Gráfica

Eje X:

- Representa "Días desde 12 marzo 2020"

Eje Y:

- Muestra "Casos diarios"

Datos Representados:

Curva negra:

- Representa "Datos Reales (aprox.)"

Curva roja discontinua:

- Representa "Modelo SEIR"


Características Visuales:

- La gráfica muestra un pico significativo en los casos en torno a los 150 días desde el inicio, con valores máximos que superan los 175,000.
- La curva de datos reales aparece casi plana en comparación con la curva del modelo SEIR.

Análisis General:

- Se puede observar una comparación entre los datos reales de casos de COVID-19 y la predicción del modelo SEIR, lo que sugiere diferencias significativas en la evolución de la pandemia en Bolivia durante ese período.

4) Modelo SEIR



5) Interpretación de la gráfica

Ejes del Gráfico:

- Eje X: Días desde el 12 de marzo de 2020.
- Eje Y: Población afectada, en términos relativos (0 a 1).

Curvas del Modelo:

Susceptibles (línea azul):

- Representa a la población que aún no ha contraído la enfermedad.
- Muestra una disminución a medida que más personas se infectan.

Expuestos (línea naranja):

- Refleja a aquellas personas que han estado en contacto con el virus pero aún no son infecciosas.

- Presenta un aumento inicial que luego disminuye a medida que los expuestos se convierten en infectados o se recuperan.

Infectados (línea verde):

- Indica la cantidad de personas actualmente infectadas y que pueden contagiar a otros.
- Muestra un pico en su cantidad, representando el momento de mayor propagación de la enfermedad.

Recuperados (línea roja):

- Incluye a las personas que se han recuperado de la enfermedad.
- Su tendencia muestra un aumento continuo a medida que los infectados superan la enfermedad.

Interpretación General:

- El gráfico ilustra cómo evoluciona la epidemia en una población a lo largo del tiempo.
- Al principio, hay un gran número de susceptibles que desciende a medida que las infecciones aumentan, lo que lleva a un aumento de recuperados eventualmente.
- Las secciones indican los diferentes estados de la población ante la enfermedad, brindando una visión general de la dinámica epidemiológica.

COMPARACIÓN ENTRE LOS DOS MODELOS

Aspecto	Modelo Empírico (1°)	Modelo SEIR (2°)
Base matemática	Funciones ajustadas a datos de Bolivia	Ecuaciones diferenciales (SEIR)
Pico estimado	Muy cercano al real (1702 casos)	Desfasado y exagerado (193.986 casos)
Fecha del pico	Julio 25 (correcto)	Agosto tardío (error de +27 días)
Total de casos 2020	≈ 160.000 (correcto)	Desajustado (muchísimo mayor)
Interpretación	Ajustado a la realidad boliviana	Representa una pandemia “idealizada” sin cuarentena ni factores sociales

Ventaja	Refleja bien los datos reales	Más general y aplicable a cualquier país si se calibra
Desventaja	No sirve fuera del contexto boliviano	Mal ajuste sin calibración, errores grandes

TERCER MODELO: Modelo Logístico y Gompertz

1) Explicación de los Modelos

- Logístico: El modelo logístico es una función sigmoide que describe cómo una población crece rápidamente al principio, luego reduce su crecimiento y finalmente se estabiliza en un valor máximo.

Parámetros Clave:

K: Capacidad de carga (máximo de casos posibles) → "El techo de la epidemia"

r: Tasa de crecimiento → "Qué tan rápido se propaga"

t₀: Punto de inflexión → "Cuándo ocurre el crecimiento máximo"

Características:

Forma de S simétrica

Crecimiento exponencial inicial

Desaceleración gradual

Estabilización en el valor K

Punto de inflexión justo en la mitad

- Gompertz: El modelo Gompertz es una función asimétrica que crece más rápido que el logístico pero tiene un descenso más lento. Es mejor para modelar epidemias con crecimiento rápido pero desaceleración prolongada.

Parámetros Clave:

a: Asíntota superior (valor máximo) → "El techo"

b: Desplazamiento horizontal → "Cuándo empieza"

c: Tasa de crecimiento → "Qué tan rápido crece"

Características:

Forma asimétrica

Crecimiento más rápido al inicio

Descenso más lento que el ascenso

Sin punto de inflexión claro

Mejor para epidemias reales

2) Explicación de los Datos Obtenidos

```
=====
MODELO EPIDEMIOLOGICO COVID-19 BOLIVIA 2020
USANDO FUNCIONES GENERALES
=====
```

```
=====
ANALISIS DE MODELOS EPIDEMIOLOGICOS - BOLIVIA 2020
=====
```

DATOS REALES (APROXIMADOS):

Pico de casos: 1734 casos

Día del pico: 142 (30-Jul)

Casos totales aproximados: 157601

Tasa de ataque: 1.36%

MODELO LOGISTICO:

Capacidad de carga (K): 757 casos

Tasa de crecimiento (r): 0.1510

Punto de inflexion (t0): 93 dias

R^2: 0.3785

MODELO GOMPERTZ:

Asintota superior (a): 727 casos

Parametro de desplazamiento (b): 9.9999

Tasa de crecimiento (c): 0.0384

R^2: 0.3107

OBSERVACIONES:

Ambos modelos capturan la forma general de la curva epidemica

El modelo logistico es mas adecuado para epidemias con simetria

El modelo Gompertz tiene un crecimiento mas rapido y descenso mas lento

Los residuales muestran donde los modelos no capturan variaciones especificas

PS C:\Users\DELL\Desktop\universidad\Modelado\CODIGOS>

Resultados empíricos aproximados

El análisis de los registros oficiales muestra que el máximo diario de contagios alcanzó aproximadamente 1,734 casos, ocurrido en el día 142 desde la detección del primer caso (30 de julio de 2020).

El número total estimado de casos en 2020 fue de 157,601, lo que corresponde a una tasa de ataque de 1.36%, valor relativamente bajo en comparación con otros países de la región y del mundo.

Capacidad explicativa de los modelos

El modelo logístico presentó un coeficiente de determinación $R^2 = 0.3785$, mientras que el modelo Gompertz alcanzó un $R^2 = 0.3107$.

En ambos casos, los valores están muy por debajo del umbral de aceptabilidad ($R^2 > 0.6$), lo que evidencia un ajuste deficiente y una baja capacidad de representación de la dinámica epidemiológica real en Bolivia.

Causas del bajo ajuste

1. Subestimación de los parámetros de capacidad:

- Capacidad logística (K) proyectada: **757 casos** vs. valor real: **1,734 casos**.
- Asíntota del modelo Gompertz (a): **727 casos** vs. valor real: **1,734 casos**.


2. Estructura atípica de la curva epidemiológica en Bolivia:

- Crecimiento inicial más lento de lo esperado ($r = 0.1510$, en contraste con valores típicos superiores a 0.3).
- Presencia de una meseta prolongada en lugar de un pico agudo.
- Descenso gradual y sostenido tras el máximo de contagios.
- Manifestación de múltiples olas secundarias que interrumpieron la continuidad de la curva.

Factores contextuales determinantes en Bolivia

- **Condiciones geográficas:** la marcada variabilidad altitudinal generó diferencias significativas en la dinámica de transmisión entre altiplano, valles y zonas tropicales; además, la dispersión poblacional provocó distintos tiempos de llegada del virus a comunidades aisladas.
- **Factores sociales:** la aplicación de cuarentenas rígidas, pero intermitentes, la migración interna que redistribuyó los focos de contagio y el peso de la economía informal —que obligó a la circulación constante de personas— influyeron en la propagación heterogénea del virus.
- **Aspectos epidemiológicos y del sistema de salud:** la transmisión comunitaria sostenida, el subregistro de casos por limitaciones en la detección y el reporte, así como la fragmentación estructural del sistema sanitario, contribuyeron a distorsionar la curva observada respecto a las predicciones teóricas de los modelos.


3) Interpretación de los Gráficos



1. Comparación de modelos epidemiológicos

La curva negra representa los casos reales diarios reportados en Bolivia durante 2020.

- Se observa un **pico máximo de ~1,734 casos diarios** hacia finales de julio, seguido por un descenso prolongado y con oscilaciones secundarias.
- Los modelos teóricos subestiman la magnitud del brote:
 - **Logístico:** máximo estimado de ~757 casos.
 - **Gompertz:** máximo estimado de ~727 casos.
- Mientras que la curva real muestra una meseta extensa y un descenso irregular, los modelos asumen un comportamiento suavizado y simétrico, lo cual explica los bajos valores de ajuste ($R^2 < 0.4$).
- Las líneas verticales marcan hitos importantes: inicio de cuarentenas, pico epidémico, flexibilización de medidas y la segunda ola. La discrepancia temporal muestra que los modelos no incorporan adecuadamente el efecto de estas intervenciones.



2. Análisis de residuales

Los residuales corresponden a la diferencia entre los casos observados y los estimados por los modelos.

- **Durante la fase de crecimiento:**
 - Los residuales son positivos y crecientes, lo que indica que los modelos subestiman de manera sistemática los contagios reales.
- **En el pico epidémico:**
 - Los residuales alcanzan valores superiores a +1,000 casos diarios, confirmando que los modelos no reproducen la magnitud del brote.
- **Durante la fase de descenso:**
 - Los residuales se vuelven negativos, evidenciando que los modelos sobreestiman la velocidad de caída, mientras que en la realidad el descenso fue lento y heterogéneo.

En conjunto, el análisis de residuales confirma que los modelos logísticos y Gompertz no representan con fidelidad la dinámica epidemiológica boliviana, debido a la influencia de factores externos como la heterogeneidad geográfica, las medidas sociales intermitentes y las limitaciones del sistema de salud.

MODELO DE BLACK SCHOLES - OPCIONES EUROPEAS

1) Explicación del Modelo

El modelo de Black–Scholes es una de las herramientas más utilizadas en finanzas para valorar opciones europeas.

Una opción europea es un contrato financiero que da el derecho (pero no la obligación) de comprar (Call) o vender (Put) un activo subyacente a un precio de ejercicio (strike) en una fecha de vencimiento determinada.

El modelo supone:

- Los precios del activo siguen un movimiento browniano geométrico.
- Los mercados son eficientes (sin arbitraje).
- La tasa de interés libre de riesgo y la volatilidad son constantes.

2) Fórmulas

Opción Call:

$$C(S, K, T, r, \sigma) = SN(d_1) - Ke^{-rT}N(d_2)$$

Opción Put:

$$P(S, K, T, r, \sigma) = Ke^{-rT} \cdot N(-d_2) - S \cdot N(-d_1)$$

con:

$$d_1 = \frac{\ln(\frac{S}{K}) + (r + \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}$$

3) Definición de Variables

- S : Precio spot del subyacente
- K : Precio de ejercicio (strike)
- T : Tiempo al vencimiento(en años)
- r : Tasa de interés libre de riesgo (anual)
- σ : Volatilidad anualizada del activo subyacente
- $N(\cdot)$: Función de distribución normal acumulada
- $\phi(\cdot)$: Función de densidad de probabilidad normal estándar

4) Griegas Principales

- Delta: Mide la sensibilidad del precio de la opción respecto al subyacente:

$$\Delta_{call} = N(d_1), \quad \Delta_{put} = N(d_1) - 1$$

- Vega: Mide la sensibilidad respecto a cambios en la volatilidad

$$v = \frac{\partial C}{\partial \sigma} = S\phi(d_1)\sqrt{T}$$

- Theta: Mide la pérdida de valor de la opción con el paso del tiempo:

$$\Theta = \frac{\partial C}{\partial T}$$

5) Explicación de las Funciones

- `black_scholes_call(S,K,T,r,sigma)` → calcula el precio de una opción Call.
- `black_scholes_put(S,K,T,r,sigma)` → calcula el precio de una opción Put.
- `delta_call(S,K,T,r,sigma)` → sensibilidad del Call respecto al precio del subyacente.
- `delta_put(S,K,T,r,sigma)` → sensibilidad del Put respecto al precio del subyacente.
- `vega(S,K,T,r,sigma)` → sensibilidad de la opción a cambios en la volatilidad.

Estas funciones utilizan distribuciones estadísticas de la librería `scipy.stats.norm` para calcular las probabilidades asociadas a d_1 y d_2 .

6) Explicación del Código


El código se divide en tres partes principales:

1. Definición de parámetros de entrada:
 - $S_0 = 227.55$:precio spot del activo.
 - $\sigma = 28.79\%$:volatilidad anualizada.
 - $r = 2\%$:tasa libre de riesgo.
 - $T = 30/365$:tiempo al vencimiento en años.
2. Cálculo de valores en rangos de strikes y tiempos:
 - Se generan arrays de valores de K y T para analizar el comportamiento del modelo en distintos escenarios.
3. Visualización de resultados:
 - Se grafican curvas 2D (precios, delta, vega, decaimiento temporal).
 - Se generan superficies 3D que muestran la relación entre strike, tiempo y el precio de la opción.

7) Explicación de las Gráficas

Precios Call y Put vs Strike


- Call más caro cuando K es bajo.
- Put más caro cuando K es alto.
- En el punto at-the-money (ATM), los precios de Call y Put se equilibran.



La gráfica de Precios de Call y Put vs Strike muestra la relación fundamental entre el precio de ejercicio y el valor de las opciones europeas. Se observa que el precio de la call disminuye conforme aumenta el strike, ya que opciones con strikes más altos tienen menor probabilidad de terminar in-the-money, mientras que el precio de la put aumenta con strikes más elevados porque estas ganan valor cuando el subyacente cae por debajo del precio de ejercicio. El punto donde se cruzan las curvas (cerca del spot actual de 227.55) representa el punto ATM (at-the-money), donde ambas opciones tienen precios similares y máxima incertidumbre sobre su valor intrínseco al vencimiento.

Decaimiento temporal del Call ATM


- Muestra cómo la prima de una opción disminuye a medida que se acerca la fecha de vencimiento.
- Ejemplo: el Call en ATM pierde valor hasta casi cero al vencimiento.



La gráfica muestra cómo el precio de una opción call ATM pierde valor con el paso del tiempo debido al decaimiento temporal (theta). El precio disminuye más rápidamente cuando faltan pocos días para el vencimiento, ya que la probabilidad de que la opción termine in-the-money se reduce aceleradamente. La curva es convexa, indicando que la erosión del valor temporal se acelera conforme se acerca la fecha de expiración.

Delta Call y Put vs Strike


- Call: va de 0 (fuera de dinero) a 1 (muy dentro de dinero).
- Put: va de -1 a 0.
- En ATM, $\Delta_{call} \approx 0.5$ y $\Delta_{put} \approx -0.5$.



El delta de la call muestra valores cercanos a 1 para strikes muy por debajo del spot, indicando que estas opciones se comportan casi como el subyacente, mientras que para strikes muy altos el delta se aproxima a cero, reflejando su baja probabilidad de ejercicio. El delta de la put presenta el comportamiento inverso, con valores cercanos a -1 para strikes elevados y próximos a cero para strikes bajos. En la zona ATM (alrededor del spot de 227.55), ambos deltas se sitúan cerca de ± 0.5 , lo que evidencia la máxima sensibilidad del precio de las opciones ante movimientos del subyacente en este punto de equilibrio.

Vega vs Strike

- Máximo en ATM → las opciones en este punto son las más sensibles a cambios en la volatilidad.
- Opciones ITM/OTM muestran menor sensibilidad.




La gráfica muestra que la vega alcanza su máximo valor en opciones cercanas al precio spot actual (227.55), indicando que las opciones ATM son las más sensibles a cambios en la volatilidad. Esto ocurre porque existe máxima incertidumbre sobre si estas opciones terminarán in-the-money o out-of-the-money. A medida que nos alejamos del strike ATM hacia opciones claramente ITM o OTM, la vega disminuye rápidamente, ya que el resultado de estas opciones está más definido y son menos afectadas por variaciones en la volatilidad.


Superficies 3D de Call y Put

- El precio depende simultáneamente de strike y tiempo al vencimiento.
- A mayor tiempo, la opción es más cara.
- Calls se encarecen con strikes bajos, Puts con strikes altos.

Superficie de precios Call (Strike vs Tiempo)



Superficie de precios Put (Strike vs Tiempo)



La superficie 3D muestra cómo el precio de las opciones call y put varía simultáneamente con el strike y el tiempo hasta el vencimiento. Para las calls, los precios más elevados se observan con strikes bajos y tiempos largos, mientras que las puts alcanzan valores máximos con strikes altos y

mayor tiempo restante. Ambas superficies muestran que el valor temporal decae aceleradamente conforme se acerca el vencimiento, especialmente en la zona ATM donde la curvatura es más pronunciada, reflejando la erosión del valor por el paso del tiempo y la mayor sensibilidad cerca del punto de equilibrio.

SIMULACIÓN DE INCENDIO EN BOLIVIA

GRÁFICOS:

El código utiliza **GeoPandas** y **Matplotlib** para trabajar con datos espaciales en formato *GeoPackage* (.gpkg).

Los pasos principales que sigue son:

1. Importar librerías necesarias:

- `geopandas` para leer y manejar datos espaciales.
- `matplotlib.pyplot` para realizar las visualizaciones.

2. Lectura del archivo geoespacial:

Se usa `gpd.read_file()` para abrir el archivo .gpkg que contiene la información geográfica (bosques, humedales, elevaciones, etc.).

3. Exploración inicial de los datos:

- `print(gdf.columns)` muestra los nombres de las columnas (atributos).
- `print(gdf.head())` muestra las primeras filas de la tabla para conocer la estructura y verificar la información cargada.


4. Visualización de los datos en un mapa:

Se usa el método `.plot()` de GeoPandas:

- `column=" "` indica qué atributo se usará para diferenciar los polígonos.
- `legend=True` agrega la leyenda.
- `cmap="Set3"` define la paleta de colores.
- `figsize=(10, 8)` ajusta el tamaño de la figura.

El resultado es un **mapa temático** que representa las categorías de los elementos espaciales (por ejemplo, tipos de bosques), lo que permite analizar visualmente su distribución en el territorio.

1) Mapa de bosques




```
Index(['ogc_fid', 'gridcode', 'supha', 'tipo_bosqu', 'geometry'], dtype='object')
ogc_fid  gridcode  supha  tipo_bosqu  geometry
0      933      1.0  112.365597  Bosque Secos Interandinos  MULTIPOLYGON (((-64.38735 -19.08375, -64.38735...
1      934      1.0   0.216846  Bosque Secos Interandinos  MULTIPOLYGON (((-64.2426 -19.24, -64.24305 -19...
2      935      1.0  11.862195  Bosque Secos Interandinos  MULTIPOLYGON (((-64.37336 -19.22625, -64.37336...
3      936      1.0  53.867741  Bosque Secos Interandinos  MULTIPOLYGON (((-64.35983 -19.22919, -64.35983...
4      937      1.0  23.642877  Bosque Secos Interandinos  MULTIPOLYGON (((-64.38827 -19.2264, -64.388 -1...
```

El resultado obtenido es un **mapa de distribución de bosques**, que permite observar cómo se encuentran organizados espacialmente los distintos tipos de cobertura forestal. Esto es fundamental para:

- Identificar la diversidad de ecosistemas forestales.
- Analizar patrones de concentración o dispersión de bosques.
- Servir como insumo en estudios de conservación y ordenamiento territorial.

2) Mapa de humedales




```
PS C:\Users\DELL\Desktop\universidad\Modelado\Prueba> & C:/Users/DELL/AppData/Local/Microsoft/WindowsAppModel/WindowsAppModel/WindowsAppModel/humedad.py
Index(['ogc_fid', 'gml_id', 'codigo', 'tipo', 'nombre', 'geometry'], dtype='object')
ogc_fid  gml_id  codigo  tipo  nombre  geometry
0        1  humedales.1    3  Humedal  None  MULTIPOLYGON (((-66.26451 -11.01903, -66.26573...
1        2  humedales.2    3  Humedal  None  MULTIPOLYGON (((-66.17441 -11.01354, -66.18284...
2        3  humedales.3    3  Humedal  None  MULTIPOLYGON (((-66.55201 -11.08683, -66.57326...
3        4  humedales.4    3  Humedal  None  MULTIPOLYGON (((-67.54323 -11.1776, -67.552 -1...
4        5  humedales.5    3  Humedal  None  MULTIPOLYGON (((-67.55884 -11.1702, -67.56445 ...
```

El resultado es un **mapa binario de humedales**, en el que se observa de manera clara qué áreas presentan humedad y cuáles no. Este tipo de visualización resulta útil porque:

- Permite identificar rápidamente las áreas con presencia de humedales.
- Ayuda a analizar la distribución espacial de estas zonas en el territorio.
- Constituye una base para estudios ambientales, conservación de ecosistemas y gestión de recursos hídricos.

3) Mapa de elevaciones




```
PS C:\Users\DELL\Desktop\universidad\Modelado\Prueba> & C:/Users/DELL/AppData/Local/Micro
/elevacion.py
Index(['ogc_fid', 'objectid', 'entity', 'layer', 'level_', 'color', 'altura',
      'geometry'],
      dtype='object')
   ogc_fid  objectid entity layer  level_  color  altura      geometry
0         1         1  Point   36      36     3    244  POINT (-63.01832 -17.1078)
1         2         2  Point   36      36     3   468  POINT (-63.8257 -17.52047)
2         3         3  Point   36      36     3   307  POINT (-63.20613 -17.4041)
3         4         4  Point   36      36     3   415  POINT (-63.28066 -17.70666)
4         5         5  Point   36      36     3  2075  POINT (-63.8706 -17.96215)
```

El resultado es un **mapa de elevaciones**, donde se pueden identificar las variaciones topográficas del territorio.

Este tipo de visualización es especialmente útil porque:


- Permite observar la distribución de zonas bajas, medias y altas en el área de estudio.
- Facilita el análisis geográfico para estudios ambientales, planificación territorial y gestión de recursos naturales.
- Proporciona una base cartográfica para relacionar la altitud con otros factores, como el tipo de vegetación, clima o presencia de ecosistemas específicos.

4) Mapa completo



Para generar estas visualizaciones se utilizó **GeoPandas en Python**, lo que permitió cargar las capas de bosques, humedales y elevaciones mediante líneas como `bosques = gpd.read_file("bosques.gpkg")` y asegurarse de que todas compartieran el mismo sistema de coordenadas (`to_crs(target_crs)`). Posteriormente, se realizó la **superposición espacial** de bosques y humedales usando `gpd.overlay(bosques, humedales, how="intersection")` y se definió un **área de análisis mediante un cuadrado** (`analysis_square = box(cx - half, cy - half, cx + half, cy + half)`) para recortar las capas y enfocarse en la zona más relevante. Gracias a estos pasos, las imágenes muestran claramente la **intersección de bosques con humedales** y la distribución de elevaciones, facilitando el análisis de cómo la **vegetación, la humedad y el relieve** pueden influir en la propagación de incendios y la identificación de áreas vulnerables.

PRIMER MODELO: Propagación de fuego con Elevaciones



```
[Running] python -u "c:\Users\omkrf\Desktop\Nuev py\Modelado\EspacioTiempo\mapas\mapas2.py"  
Zona vacía, seleccionando automáticamente una zona válida...  
Nueva zona definida: (-66.5602571775, -19.6258472825) a (-63.609832225000005, -16.370603935000002)  
[Done] exited with code=0 in 406.63 seconds
```

1) Definición de la zona de análisis:

- Se utilizó la función `definirzona()` para recortar las capas a un **área específica**, enfocando el estudio en la región más relevante.
- En caso de que la zona seleccionada no tuviera datos, se eligió automáticamente un área válida basada en los límites de las elevaciones.

2) Preparación de la grilla de elevaciones:

- Se extrajeron las coordenadas de los puntos de elevación y sus valores (`coords` y `z`).
- Se generó una **grilla regular** con `np.meshgrid` y se interpolaron los valores de altura usando `griddata`.
- Esto permitió construir un **relieve continuo** sobre el cual simular la propagación del fuego.


3) Modelo de propagación de incendios:

- Se definió un **foco inicial de ignición** en el centro de la grilla:
 $T[cx-2:cx+3, cy-2:cy+3] = 1000$
- La propagación se calculó con un **operador laplaciano** y parámetros de difusión (**D**, **alpha**) y temperatura de ignición (**Tign**).
- La función **get_Tem()** actualiza la temperatura de cada celda en cada paso de tiempo (**dt**).

3) Visualización animada en 3D:

- Se utilizó **FuncAnimation** para mostrar cómo el fuego se propaga sobre el relieve interpolado.
- La superficie del terreno se representó con **plot_surface(X, Y, Z, cmap="terrain")**, y el fuego se superpuso con colores calientes (**plt.cm.hot**) según la intensidad.
- Esto permite **observar la influencia de la topografía y la distribución espacial de las elevaciones** sobre la dinámica del incendio, destacando las zonas más vulnerables.

SEGUNDO MODELO: Propagación de fuego con Bosques y Humedales



```
[Running] python -u "c:\Users\omkrf\Desktop\Nuev py\Modelado\EspacioTiempo\mapas\mapas2.py"
Zona vaca, seleccionando automáticamente una zona válida...
Nueva zona definida: (-67.23570503650133, -18.33095404637751) a (-64.28528008400133, -15.07571069887751)
[Done] exited with code=0 in 663.476 seconds
```

1) Carga de capas y CRS:

- Se cargaron las capas de **bosques, humedales y elevaciones** usando `gpd.read_file()`.
- Todas las capas se unificaron a un mismo sistema de coordenadas (`to_crs(target_crs)`) para permitir su superposición correcta.

2) Definición de zona de análisis:

- La función `definirzona()` recorta las capas a un **rectángulo definido por coordenadas**.
- Si la zona seleccionada no tiene datos, se elige automáticamente un área válida usando `random.uniform()` para generar nuevas coordenadas.

3) Preparación de la grilla de elevaciones:

- Se generan coordenadas de los puntos y sus valores de altura (`coords` y `z`).
- Se interpola la grilla de elevación con `griddata` y `np.meshgrid` para obtener un **relieve continuo** sobre el que simular la propagación del fuego.

4) Cálculo de factores de propagación:

- Se definieron factores por **tipo de bosque, presencia de humedal y elevación**, usando la función `calcular_expansion()`.
- Cada celda de la grilla recibe un valor de **factor de expansión**, combinando humedad, inflamabilidad del bosque y altura, que influye directamente en la velocidad de propagación del fuego.

5) Modelo de propagación de incendios:


- Se inicia la ignición en el centro de la grilla (`T[cx-2:cx+3, cy-2:cy+3] = 1000`).
- La propagación se calcula con un **operador laplaciano**, parámetros de difusión (`D`, `alpha`) y temperatura de ignición (`Tign`).
- La función `get_Tem()` actualiza la temperatura de cada celda considerando los **factores ambientales** de cada ubicación.

6) Visualización animada en 3D:

- Se utiliza `FuncAnimation` para mostrar cómo el fuego se propaga sobre el relieve interpolado.
- La superficie del terreno se representa con `plot_surface(X, Y, Z, cmap="terrain")`, mientras que la propagación del fuego se superpone con colores calientes (`plt.cm.hot`) según intensidad.

- Se muestra información contextual del **tipo de bosque**, **presencia de humedal** y **elevaciones** en el centro del área (`ax.text2D`), permitiendo relacionar los factores ambientales con la propagación del fuego.

TERCER MODELO: Propagación de fuego con datos cuantitativos



```
[Running] python -u "c:\Users\omkrf\Desktop\Nuev py\Modelado\EspacioTiempo\mapas\mapas2.py"
CRS esta en grados (EPSG:4326), re proyectando a UTM...
Zona vacia, seleccionando automaticamente una zona valida...
Nueva zona definida: (475241.028216108, 8528275.862161439) a (788696.1969423937, 8889302.46648679)

Resultados de la simulacion:
Tiempo total simulado: 12.00 unidades de tiempo
Area total quemada: 96481.0184 km^2
Velocidad promedio de propagacion: 8040.0849 km^2/unidad de tiempo
Bosque mas afectado: Bosque Amazónico (2084 celdas)
% de propagacion en humedales: 4.03%

[Done] exited with code=0 in 438.768 seconds
```

1) Carga de capas y CRS:

- Se cargaron las capas de **bosques**, **humedales** y **elevaciones** con `gpd.read_file()`.
- Se verificó que el CRS fuera métrico; si estaba en grados, se re proyectó a UTM (`EPSG:32719`) para trabajar correctamente en metros.

2) Definición de zona de análisis:

- La función `definirzona()` recorta las capas a un **rectángulo mínimo de 10x10 km**, garantizando un área de estudio suficiente.

- Si la zona inicial está vacía, se selecciona automáticamente un área válida usando `random.uniform()` para generar nuevas coordenadas.

3) Preparación de la grilla de elevaciones:

- Se generaron las coordenadas y alturas (`coords` y `z`) y se interpoló la grilla con `griddata` para obtener un **relieve continuo** sobre el cual simular la propagación del fuego.

4) Factores de propagación ambiental:

- Se definieron factores por **tipo de bosque**, **presencia de humedal** y **elevación** usando la función `calcular_expansion()`.
- Cada celda de la grilla recibe un valor de **factor de expansión**, combinando la inflamabilidad del bosque, la humedad del humedal y la altura sobre el nivel del mar.
- También se creó una **matriz de metadatos** (`bosque_grid` y `humedal_grid`) para rastrear qué tipo de bosque o humedal estaba presente en cada celda.

5) Modelo de propagación de incendios:

- La ignición inicial se ubica en el centro de la grilla (`T[cx-2:cx+3, cy-2:cy+3] = 1000`).
- La propagación se calcula con un **operador laplaciano** y parámetros de difusión (`D`, `alpha`) y temperatura de ignición (`Tign`).
- La función `get_Tem()` actualiza la temperatura de cada celda considerando los **factores ambientales** y marca las celdas que ya fueron quemadas (`quemado |= (Tn > Tign)`).

6) Visualización animada en 3D:


- Se usa `FuncAnimation` para mostrar la propagación del fuego sobre el relieve (`plot_surface`).
- El fuego se representa con colores calientes (`plt.cm.hot`) y se superpone al terreno.
- Se muestra información del **tipo de bosque** y **presencia de humedal** en el centro del área (`ax.text2D`).

7) Resultados cuantitativos de la simulación:

- Se calcula el **área total quemada** en km² y la **velocidad promedio de propagación**.
- Se identifica el **bosque más afectado** y el **porcentaje de propagación en humedales**.

- Esto permite **cuantificar el impacto del fuego según tipo de vegetación y condiciones ambientales**, facilitando el análisis de vulnerabilidad y planificación de mitigación.

CUARTO MODELO: Propagación de fuego con Viento



```
[Running] python -u "c:\Users\omkrf\Desktop\Nuev py\Modelado\EspacioTiempo\mapas\mapas2.py"

Resultados de la simulacion:
Tiempo total simulado: 12.00 unidades de tiempo
Area total quemada: 6113.0385 km^2
Velocidad promedio de propagacion: 509.4199 km^2/unidad de tiempo
Bosque mas afectado: Bosque Amazónico (2564 celdas)
% de propagacion en humedales: 3.67%

[Done] exited with code=0 in 83.618 seconds
```

1) Carga de capas y CRS:

- Se importan las capas de **bosques, humedales y elevaciones** (`gpd.read_file()`).
- Se asegura que el CRS sea métrico; si estaba en grados, se reproyecta a UTM (`EPSG:32719`) para trabajar con coordenadas en metros.

2) Definición de zona de análisis:

- La función `definirzona()` permite **seleccionar automáticamente una zona aleatoria** si no se proporcionan coordenadas, asegurando un **mínimo de 10x10 km**.
- Se recortan las capas a la zona definida usando `gpd.clip()`.

3) Preparación de la grilla de elevaciones:

- Se interpolan los puntos de elevación (`griddata`) para generar un **relieve continuo** sobre el que simular la propagación del fuego.
- La grilla se define con 60x60 celdas (`nx, ny = 60, 60`).

4) Factores de propagación ambiental:

- Se definen factores según **tipo de bosque**, **presencia de humedal** y **elevación**, usando `calcular_expansion()`.
- Se generan matrices de metadatos `bosque_grid` y `humedal_grid` para identificar qué vegetación y humedales hay en cada celda.

5) Modelo de propagación de incendios con viento:

- Se inicia el fuego en el centro de la grilla (`T[cx-2:cx+3, cy-2:cy+3] = 1000`).
- La propagación se calcula con el **operador laplaciano**, parámetros de difusión (`D`, `alpha`) y temperatura de ignición (`Tign`).
- El viento se incorpora mediante la función `wind_effect(T)`, ajustando la propagación en las direcciones de `vx` y `vy` con un `wind_factor`.
- La función `get_Tem(T)` actualiza las temperaturas y marca las celdas quemadas (`quemado |= (Tn > Tign)`).

6) Visualización animada en 3D:

- Se usa `FuncAnimation` para mostrar la propagación del fuego sobre el terreno (`plot_surface`).
- El fuego se visualiza con colores calientes (`plt.cm.hot`) y se superpone sobre la topografía.
- Se muestra información del **bosque y presencia de humedal** en el centro del área (`ax.text2D`).

7) Resultados cuantitativos de la simulación:

- Se calcula el **área total quemada** en km^2 y la **velocidad promedio de propagación**.
- Se identifica el **bosque más afectado** y el **porcentaje de propagación en humedales**.
- Esto permite **evaluar el impacto del fuego considerando viento, tipo de vegetación y humedad**, útil para planificación y mitigación de riesgos.

CONCLUSIÓN

- **El primer modelo empírico es el más adecuado para describir la evolución del COVID-19 en Bolivia en 2020 porque:**
 - Usa datos reales de hitos y estadísticas locales.
 - Reproduce correctamente el pico, la fecha y el total de casos.
 - Refleja la influencia de medidas sanitarias, movilidad y contexto socio-geográfico.
- **El modelo SEIR con `get_euler`, aunque matemáticamente elegante, falla sin calibración: predice un pico tardío y exageradamente alto.**
 - Sin embargo, es valioso porque permite entender la dinámica epidemiológica en abstracto y podría usarse si se ajustan los parámetros (β , γ , σ) mediante optimización con los datos reales.
- **Los modelos Logístico y Gompert no logran describir en su totalidad los eventos sucedidos en Bolivia. A pesar de ello la diferencia entre las simulaciones y los datos reales no es exagerada como con modelos más genéricos.**
 - Subestimar la capacidad del sistema de salud
 - No capturar la complejidad de la epidemia boliviana
 - Ignorar la heterogeneidad geográfica y temporal
- **Modelo de Black-Scholes**
 - El modelo de Black-Scholes es una herramienta poderosa y ampliamente utilizada en las finanzas modernas, útil tanto en contextos académicos como profesionales. Si bien presenta limitaciones, su capacidad para estimar precios y analizar el riesgo de las opciones lo convierte en un punto de partida esencial para estudios más avanzados y modelos más complejos que incorporen factores del mundo real.
- **Simulación de propagación de fuego**
 - Estos modelos combinaron **información geográfica, propiedades del terreno y dinámica del fuego** para ofrecer una herramienta de análisis integral. Cada versión fue progresivamente más realista: desde la simulación basada únicamente en elevaciones, hasta la incorporación de factores ambientales y viento, demostrando cómo la modelización computacional puede **apoyar decisiones de prevención y mitigación de incendios forestales**.

Bibliografía

- Mathieu, E., Ritchie, H., Rodés-Guirao, L., Appel, C., Giattino, C., Hasell, J., Macdonald, B., Dattani, S., Beltekian, D., & Ortiz-Ospina, E. (2020, 5 marzo). *Coronavirus pandemic (COVID-19)*. Our World In Data. <https://ourworldindata.org/coronavirus/country/bolivia>
- CSSEGISandData. (s. f.). *GitHub - CSSEGISandData/COVID-19: Novel Coronavirus (COVID-19) Cases, provided by JHU CSSE*. GitHub. <https://github.com/CSSEGISandData/COVID-19>
- *Bolivia*. (s. f.). OPS/OMS | Organización Panamericana de la Salud. <https://www.paho.org/es/bolivia>

- Ministerio de Salud y Deportes de Bolivia. (s. f.). *Ministro de Salud reporta dos casos confirmados de coronavirus y pide calma a la población.* <https://www.minsalud.gob.bo/3967-ministro-de-salud-reporta-dos-casos-confirmados-de-coronavirus-y-pide-calma-a-la-poblacion?highlight=WyJjb3JvbmF2aXJ1cyIsImNvcuYXJpYXMiLCJjb3JvbmVsliwiY29yb25hcmlhIiwiaY29yb25pbGxhIiwiaY29yb25hZG8iLCJjb3JvbmF2aXJ1c1x1MjAxZCwiLCJjb3JvbmEiLCJjb3Jvblx1MDBlMW5kb3NliwiY29yb25cdTAwZjMiXQ==>
- *Ministerio de Salud y Deportes de Bolivia - Ministerio de Salud y Deportes - Bolivia.* (s. f.). <https://www.minsalud.gob.bo/>
- QGIS Development Team. (2025). *QGIS Geographic Information System* (Versión X.X) [Software libre]. <https://www.qgis.org>